ΕΘΝΙΚΟ ΚΑΙ ΚΑΠΟΔΙΣΤΡΙΑΚΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΑΘΗΝΩΝ

ΣΧΟΛΗ ΘΕΤΙΚΩΝ ΕΠΙΣΤΗΜΩΝ

ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΤΗΛΕΠΙΚΟΙΝΩΝΙΩΝ

ΔΙΑΤΜΗΜΑΤΙΚΟ ΠΡΟΓΡΑΜΜΑ ΜΕΤΑΠΤΥΧΙΑΚΩΝ ΣΠΟΥΔΩΝ
«ΔΙΟΙΚΗΣΗ ΚΑΙ ΟΙΚΟΝΟΜΙΚΗ ΤΩΝ ΤΗΛΕΠΙΚΟΙΝΩΝΙΑΚΩΝ ΔΙΚΤΥΩΝ ΚΑΙ ΠΛΗΡΟΦΟΡΙΑΚΩΝ ΣΥΣΤΗΜΑΤΩΝ»

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΕΞΑΓΩΓΗ ΕΥΦΥΩΝ ΑΝΑΛΥΣΕΩΝ ΑΠΟ ΔΕΔΟΜΕΝΑ ΗΛΕΚΤΡΟΝΙΚΟΥ ΕΜΠΟΡΙΟΥ

Χρήστος Μουρτογιάννης

Επιβλέπων: Ευστάθιος Χατζηευθυμιάδης

Αθήνα, Σεπτέμβριος, 2026

ΕΘΝΙΚΟ ΚΑΙ ΚΑΠΟΔΙΣΤΡΙΑΚΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΑΘΗΝΩΝ

ΣΧΟΛΗ ΘΕΤΙΚΩΝ ΕΠΙΣΤΗΜΩΝ

ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΤΗΛΕΠΙΚΟΙΝΩΝΙΩΝ

ΔΙΑΤΜΗΜΑΤΙΚΟ ΠΡΟΓΡΑΜΜΑ ΜΕΤΑΠΤΥΧΙΑΚΩΝ ΣΠΟΥΔΩΝ
«ΔΙΟΙΚΗΣΗ ΚΑΙ ΟΙΚΟΝΟΜΙΚΗ ΤΩΝ ΤΗΛΕΠΙΚΟΙΝΩΝΙΑΚΩΝ ΔΙΚΤΥΩΝ ΚΑΙ ΠΛΗΡΟΦΟΡΙΑΚΩΝ ΣΥΣΤΗΜΑΤΩΝ»

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΕΞΑΓΩΓΗ ΕΥΦΥΩΝ ΑΝΑΛΥΣΕΩΝ ΑΠΟ ΔΕΔΟΜΕΝΑ ΗΛΕΚΤΡΟΝΙΚΟΥ ΕΜΠΟΡΙΟΥ

Χρήστος Μουρτογιάννης

Επιβλέπων: Ευστάθιος Χατζηευθυμιάδης

Αθήνα, Σεπτέμβριος, 2026

Interdepartmental Postgraduate Programme in Management and Economics of Telecommunication Networks and Information Systems

EXTRACTION OF INTELLIGENT ANALYTICS FROM E-COMMERCE DATA

Εγκρίθηκε από τριμελή εξεταστική επιτροπή

Αθήνα, Σεπτέμβριος 2026

ΕΠΙΤΡΟΠΗ ΑΞΙΟΛΟΓΗΣΗΣ

1. Επιβλέπων καθηγητής
   Ευστάθιος Χατζηευθυμιάδης

2. Μέλος επιτροπής
   Κωνσταντίνος Κολομβάτσος

3. Μέλος επιτροπής
   Μιλτιάδης Κυριακάκος

Ο/Η Προϊστάμενος/η του Τμήματος

Δημήτριος Γουνόπουλος

Υπογραφή

© Mourtogiannis, Christos, 2026.

Με επιφύλαξη παντός δικαιώματος. All rights reserved.

Δήλωση μη λογοκλοπής

Δηλώνω υπεύθυνα και γνωρίζοντας τις κυρώσεις του Ν. 2121/1993 περί Πνευματικής Ιδιοκτησίας, ότι η παρούσα εργασία είναι εξ ολοκλήρου αποτέλεσμα δικής μου ερευνητικής εργασίας, δεν αποτελεί προϊόν αντιγραφής ούτε προέρχεται από ανάθεση σε τρίτους. Όλες οι πηγές που χρησιμοποιήθηκαν (κάθε είδους, μορφής και προέλευσης) για τη συγγραφή της περιλαμβάνονται στη βιβλιογραφία.

Mourtogiannis, Christos

Υπογραφή

ΕΥΧΑΡΙΣΤΙΕΣ

Θα ήθελα να ευχαριστήσω τον επιβλέποντα καθηγητή κ. Ευστάθιο Χατζηευθυμιάδη για την επίβλεψη και την καθοδήγηση κατά την εκπόνηση της εργασίας, καθώς και τον κ. Κωνσταντίνο Κολομβάτσο για τις υποδείξεις του ως προς τη μεθοδολογική κατεύθυνση, και ιδιαιτέρως ως προς τη δομή της εμφωλευμένης συσταδοποίησης που αποτέλεσε κεντρικό στοιχείο της εργασίας. Ευχαριστώ επίσης τον κ. Μιλτιάδη Κυριακάκο για τη συμμετοχή του στην εξεταστική επιτροπή. Τέλος, ευχαριστώ την οικογένειά μου για τη στήριξη καθ' όλη τη διάρκεια των σπουδών μου.

ΠΕΡΙΛΗΨΗ

Οι επιχειρήσεις ηλεκτρονικού εμπορίου καταγράφουν πλήρες ιστορικό συναλλαγών, το οποίο ωστόσο σπανίως αξιοποιείται για τη λήψη αποφάσεων marketing και πωλήσεων. Η παρούσα εργασία σχεδιάζει και υλοποιεί σύστημα εξαγωγής ευφυών αναλύσεων από τα δεδομένα αυτά, με τεχνικές εξόρυξης δεδομένων και μηχανικής μάθησης.

Το σύστημα απαντά σε επτά ερωτήματα που τέθηκαν από πραγματικούς πελάτες ηλεκτρονικών καταστημάτων, και εφαρμόζει τρεις οικογένειες τεχνικών: εξόρυξη συχνών υποσυνόλων με τους αλγορίθμους Apriori και FP-Growth για την ανάδειξη συσχετίσεων μεταξύ προϊόντων, συσταδοποίηση δύο επιπέδων με πρώτη ομαδοποίηση ως προς περιοχή και χρόνο και δεύτερη, εντός κάθε συστάδας, ως προς χαρακτηριστικά RFM, και πρόβλεψη χρονοσειρών με εκθετική εξομάλυνση. Το πλήθος των συστάδων επιλέγεται με τον δείκτη περιγράμματος αντί να ορίζεται εκ των προτέρων, ενώ κάθε πρόβλεψη αξιολογείται εκτός δείγματος και συγκρίνεται με αφελή βασική γραμμή.

Η ανάλυση επεκτείνεται σε οικονομικούς δείκτες, με αποσύνθεση της μεταβολής των εσόδων σε έξι ροές και μέτρηση της συγκέντρωσής τους στους πελάτες.

Η αρχιτεκτονική διαχωρίζει την εισαγωγή δεδομένων από την ανάλυση μέσω δημοσιευμένου συμβολαίου δεδομένων. Ένα κατάστημα προσαρτάται είτε αποστέλλοντας τις συναλλαγές του στη μορφή αυτή είτε παραχωρώντας πρόσβαση ανάγνωσης στη βάση του, οπότε η προσάρτηση αποτελεί ζήτημα παραμετροποίησης και όχι κώδικα.

Κεντρική μεθοδολογική επιλογή αποτελεί ο διαχωρισμός μεταξύ μετρούμενων και υποτιθέμενων μεγεθών. Καθώς τα δεδομένα δεν περιέχουν κόστος πωληθέντων ούτε δαπάνες marketing, η κερδοφορία δεν υπολογίζεται ως μέτρηση αλλά ως ανάλυση ευαισθησίας πάνω σε ρητά δηλωμένες παραδοχές, απομονωμένη από τα μετρήσιμα μεγέθη σε κάθε επίπεδο του συστήματος.

Λέξεις-κλειδιά: εξόρυξη δεδομένων, ηλεκτρονικό εμπόριο, συχνά υποσύνολα, συσταδοποίηση, επιχειρηματική ευφυΐα

ABSTRACT

Electronic commerce businesses record a complete transaction history, yet that record is rarely used to support marketing and sales decisions. This thesis designs and implements a system that extracts intelligent analytics from such data using data mining and machine learning techniques.

The system answers seven questions raised by actual online retail clients and applies three families of techniques: frequent itemset mining with the Apriori and FP-Growth algorithms to surface product associations, two-level clustering that first groups by region and time and then re-clusters the customers within each group by RFM features, and time series forecasting with exponential smoothing. The number of clusters is selected by silhouette score rather than fixed in advance, and every forecast is evaluated out of sample against a naive baseline.

The analysis extends to economic indicators, decomposing revenue change into six flows and measuring how concentrated that revenue is across customers.

The architecture separates ingestion from analysis through a published data contract. A store is attached by sending its transactions in that form or by granting read access to its own database, so onboarding is configuration rather than code, and no analytical code changes.

A central methodological choice is the separation of measured from assumed quantities. Because the data contains neither cost of goods nor marketing spend, profitability is not computed as a measurement but as a sensitivity analysis over explicitly stated assumptions, isolated from the measured metrics at every level of the system.

Keywords: data mining, electronic commerce, frequent itemsets, clustering, business intelligence

ΠΙΝΑΚΑΣ ΠΕΡΙΕΧΟΜΕΝΩΝ

ΕΥΧΑΡΙΣΤΙΕΣ i

ΠΕΡΙΛΗΨΗ ii

ABSTRACT iii

ΠΙΝΑΚΑΣ ΣΥΝΤΟΜΟΓΡΑΦΙΩΝ xi

ΑΠΟΔΟΣΗ ΟΡΩΝ / ΓΛΩΣΣΑΡΙΟ xii

1 Εισαγωγή 1

1.1 Αντικείμενο και κίνητρο 1

1.2 Στόχοι της εργασίας 1

1.3 Απαίτηση γενικότητας 2

1.4 Ζήτημα ειλικρίνειας των αποτελεσμάτων 2

1.5 Δομή της εργασίας 3

2 Θεωρητικό υπόβαθρο 4

2.1 Προεπεξεργασία δεδομένων 4

2.2 Εξόρυξη συχνών υποσυνόλων 4

2.2.1 Ορισμοί 4

2.2.2 Το μέτρο της άρσης 5

2.2.3 Αλγόριθμοι 5

2.3 Συσταδοποίηση 5

2.3.1 Ο αλγόριθμος k-means 6

2.3.2 Αξιολόγηση με τον δείκτη περιγράμματος 6

2.3.3 Ιεραρχική, εμφωλευμένη ομαδοποίηση 6

2.4 Ανάλυση RFM και τμηματοποίηση πελατών 6

2.5 Οικονομικοί δείκτες ηλεκτρονικού εμπορίου 7

2.5.1 Μετρήσιμα μεγέθη 7
2.5.2 Μεγέθη που απαιτούν παραδοχές 7

3 Μεθοδολογία **8**

3.1 Το σύνολο δεδομένων 8
3.1.1 Δομή των εγγραφών 8
3.1.2 Μεγέθη του συνόλου δεδομένων μετά την εισαγωγή 8
3.1.3 Διαχείριση μη εμπορικών κωδικών 9
3.1.4 Δηλωμένοι περιορισμοί 9
3.2 Αρχιτεκτονική του συστήματος 10
3.3 Κανονικοποιημένο σχήμα δεδομένων 10
3.3.1 Η περιοχή αποθηκεύεται στην παραγγελία 10
3.3.2 Οι επιστροφές είναι αυτοτελείς εγγραφές 10
3.3.3 Η τιμή αποθηκεύεται ανά γραμμή 11
3.4 Προσαρμογείς πηγών δεδομένων 11
3.4.1 Τρεις οδοί παράδοσης δεδομένων 11
3.5 Προεπεξεργασία 12
3.6 Επαλήθευση της υλοποίησης 12

4 Περιγραφική ανάλυση δεδομένων **13**

4.1 Αντικείμενα με τις μεγαλύτερες πωλήσεις 13
4.2 Πελάτες με τις περισσότερες αγορές 14
4.3 Περιοχές με τις περισσότερες πωλήσεις 15
4.4 Χρονική κατανομή των πωλήσεων 16
4.5 Προϊόντα με τις περισσότερες επιστροφές 17
4.6 Πωλήσεις ανά εύρος τιμής 18
4.7 Πωλήσεις ανά χαρακτηριστικό προϊόντος 19

5 Εξόρυξη συχνών υποσυνόλων **21**

5.1 Κατασκευή καλαθιών αγορών 21
5.2 Πειραματική διάταξη 21

5.3 Αποτελέσματα 22
5.3.1 Σύγκριση των δύο αλγορίθμων 22
5.3.2 Ευαισθησία στο κατώφλι υποστήριξης 22
5.4 Αξιολόγηση κανόνων συσχέτισης 23
5.4.1 Οι ισχυρότεροι κανόνες 23

6 Συσταδοποίηση **26**
6.1 Χαρακτηριστικά και κανονικοποίηση 26
6.2 Επιλογή του πλήθους συστάδων 26
6.3 Πρώτο επίπεδο: περιοχή και χρόνος 27
6.4 Δεύτερο επίπεδο: υποσυστάδες RFM 28
6.5 Ερμηνεία των συστάδων 29

7 Πρόβλεψη πωλήσεων και οικονομική ανάλυση **30**
7.1 Πρόβλεψη χρονοσειρών πωλήσεων 30
7.2 Αξιολόγηση της πρόβλεψης 30
7.2.1 Αποτελέσματα και το ζήτημα της τελευταίας περιόδου 30
7.2.2 Σύγκριση με αφελή βασική γραμμή 31
7.3 Μετρήσιμοι οικονομικοί δείκτες 32
7.3.1 Ακαθάριστη αξία πωλήσεων 32
7.3.2 Ποσοστό επαναληπτικών αγορών 33
7.3.3 Διατήρηση πελατών ανά κοόρτη 33
7.3.4 Ανάλυση RFM 33
7.4 Λογιστική ανάπτυξης και ποσοτική προσαρμογή προϊόντος-αγοράς . . 34
7.4.1 Αποσύνθεση των εσόδων σε ροές 34
7.4.2 Παράγωγοι δείκτες 35
7.4.3 Συγκέντρωση εσόδων 36
7.4.4 Γενικότητα και απουσία κατωφλίων 37
7.5 Ανάλυση κερδοφορίας βάσει σεναρίων 38
7.5.1 Δηλωμένες παραδοχές 38
7.5.2 Σημεία αναφοράς της αγοράς 38

7.5.3 Αξία διάρκειας ζωής και απόσβεση 38
7.5.4 Πλέγμα ευαισθησίας 39
7.5.5 Προβολή στον χρόνο 40

8 Συζήτηση και συμπεράσματα **41**
8.1 Σύνοψη των ευρημάτων 41
8.2 Πρακτική αξιοποίηση από την επιχείρηση 41
8.3 Περιορισμοί 42
8.3.1 Απουσία στοιχείων κόστους 42
8.3.2 Απουσία δομημένης κατηγοριοποίησης 42
8.3.3 Γεωγραφική ανάλυση σε επίπεδο χώρας 42
8.3.4 Ανώνυμες πωλήσεις 42
8.3.5 Ένα σύνολο δεδομένων 43
8.4 Μελλοντικές επεκτάσεις 43
8.5 Επίλογος 43

Α Πηγαίος κώδικας **45**
Α.1 Εμφωλευμένη συσταδοποίηση 45
Α.2 Αποσύνθεση των εσόδων σε ροές 46

Β Αναλυτικά αποτελέσματα **48**
Β.1 Πλήρες πλέγμα ευαισθησίας των μοναδιαίων οικονομικών 48
Β.2 Δείκτες περιγράμματος ανά υποψήφιο πλήθος συστάδων 49

ΒΙΒΛΙΟΓΡΑΦΙΑ **50**

ΚΑΤΑΛΟΓΟΣ ΠΙΝΑΚΩΝ

3.1 Μεγέθη μετά την εισαγωγή του συνόλου δεδομένων 8

4.1 Προϊόντα με τα υψηλότερα έσοδα 13
4.2 Περιοχές με τα υψηλότερα έσοδα 15
4.3 Προϊόντα με την υψηλότερη αξία επιστροφών 17
4.4 Πωλήσεις ανά εύρος τιμής μονάδας 18
4.5 Πωλήσεις ανά χαρακτηριστικό προϊόντος 19

5.1 Σύγκριση αλγορίθμων για υποστήριξη 0,02 22
5.2 Επίδραση του κατωφλίου υποστήριξης 23
5.3 Κανόνες με την υψηλότερη άρση 24

6.1 Επιλογή του πλήθους συστάδων στο πρώτο επίπεδο 27
6.2 Συστάδες πρώτου επιπέδου 27
6.3 Υποσυστάδες RFM εντός κάθε συστάδας πρώτου επιπέδου 28

7.1 Ακρίβεια πρόβλεψης μετά τον αποκλεισμό της ημιτελούς περιόδου . . . 31
7.2 Συγκέντρωση εσόδων στους πελάτες 37
7.3 Ανάλυση ευαισθησίας των μοναδιαίων οικονομικών 39

Β.1 Πλήρες πλέγμα ευαισθησίας, 16 κελιά 48

ΚΑΤΑΛΟΓΟΣ ΔΙΑΓΡΑΜΜΑΤΩΝ/ΕΙΚΟΝΩΝ

4.1 Προϊόντα με τα υψηλότερα έσοδα 14

4.2 Περιοχές με τα υψηλότερα έσοδα 15

4.3 Μηνιαία κατανομή των εσόδων. Η κορύφωση του Νοεμβρίου επαναλαμβάνεται και στα δύο έτη, ενώ ο τελευταίος μήνας είναι ημιτελής 16

4.4 Κατανομή των εσόδων ανά ημέρα της εβδομάδας 16

4.5 Έσοδα ανά εύρος τιμής μονάδας 18

4.6 Έσοδα ανά χαρακτηριστικό προϊόντος, όπως προκύπτει από τους κανόνες λέξεων-κλειδιών 19

5.1 Κατανομή του μεγέθους των καλαθιών, σε λογαριθμική κλίμακα 22

5.2 Πλήθος συχνών υποσυνόλων και κανόνων ανά κατώφλι υποστήριξης . 23

5.3 Οι 134 κανόνες ως προς υποστήριξη και εμπιστοσύνη, χρωματισμένοι κατά άρση. Οι ισχυρότερες συσχετίσεις δεν βρίσκονται στις υψηλότερες τιμές υποστήριξης 24

6.1 Δείκτης περιγράμματος ανά υποψήφιο πλήθος συστάδων στο πρώτο επίπεδο 27

6.2 Οι υποσυστάδες RFM εντός της συστάδας των αγορών εξαγωγής. Η τριμελής ομάδα υψηλής αξίας διαχωρίζεται καθαρά στην πάνω αριστερή περιοχή 29

7.1 Καθαρή αξία πωλήσεων ανά μήνα και πρόβλεψη τριών μηνών. Ο ημιτελής Δεκέμβριος του 2011 σημειώνεται χωριστά και εξαιρείται από την προσαρμογή 31

7.2 Ακαθάριστη αξία πωλήσεων, αξία επιστροφών και καθαρή αξία ανά μήνα 32

7.3 Διατήρηση πελατών ανά κοόρτη πρώτης αγοράς. Το πλέγμα είναι εξ ορισμού τριγωνικό 33

7.4 Κατανομές των τριών μεγεθών RFM στο σύνολο των πελατών 34

7.5 Αποσύνθεση της μεταβολής των εσόδων στις έξι ροές. Οι θετικές ροές σχεδιάζονται πάνω από τον άξονα και οι αρνητικές κάτω 36

7.6 Ταχύς λόγος ανά μήνα. Τιμή κάτω της μονάδας σημαίνει συρρίκνωση των συνολικών εσόδων 36

7.7 Λόγος αξίας διάρκειας ζωής προς κόστος απόκτησης, για κάθε συνδυασμό παραδοχών. Το πλήρες πλέγμα παρατίθεται στο παράρτημα Β . . . 40

ΠΙΝΑΚΑΣ ΣΥΝΤΟΜΟΓΡΑΦΙΩΝ

API	Application Programming Interface
CAC	Customer Acquisition Cost
CLV	Customer Lifetime Value
GMV	Gross Merchandise Value
MAE	Mean Absolute Error
MAPE	Mean Absolute Percentage Error
RFM	Recency, Frequency, Monetary
RMSE	Root Mean Squared Error

ΑΠΟΔΟΣΗ ΟΡΩΝ / ΓΛΩΣΣΑΡΙΟ

association rule	κανόνας συσχέτισης
clustering	συσταδοποίηση
cohort analysis	ανάλυση κοόρτης
confidence	εμπιστοσύνη
data mining	εξόρυξη δεδομένων
dendrogram	δενδρόγραμμα
forecasting	πρόβλεψη
frequent itemset	συχνό υποσύνολο
lift	άρση
machine learning	μηχανική μάθηση
preprocessing	προεπεξεργασία
silhouette score	δείκτης περιγράμματος
support	υποστήριξη

1. Εισαγωγή

1.1 Αντικείμενο και κίνητρο

Οι επιχειρήσεις ηλεκτρονικού εμπορίου συγκεντρώνουν, από τη φύση τους, πλήρες ιστορικό των συναλλαγών τους. Κάθε παραγγελία, κάθε γραμμή προϊόντος και κάθε επιστροφή καταγράφεται με ακρίβεια που σπάνια ήταν διαθέσιμη στο παραδοσιακό λιανικό εμπόριο.

Η καταγραφή όμως δεν είναι γνώση. Στην πράξη τα δεδομένα αυτά μένουν συχνά αναξιοποίητα: χρησιμοποιούνται για λογιστικούς και λειτουργικούς σκοπούς, ενώ οι αποφάσεις marketing και πωλήσεων παίρνονται με βάση την εμπειρία και τη διαίσθηση. Το κενό ανάμεσα στα δεδομένα που υπάρχουν και στις αποφάσεις που θα μπορούσαν να στηριχτούν σε αυτά είναι το κίνητρο της εργασίας.

Αντικείμενο της εργασίας είναι η εξαγωγή χρήσιμων αναλύσεων και προβλέψεων από δεδομένα αγοραπωλησιών, με τεχνικές εξόρυξης δεδομένων και μηχανικής μάθησης, και η υλοποίηση ενός συστήματος που τις δίνει στην επιχείρηση.

1.2 Στόχοι της εργασίας

Οι αναλυτικοί στόχοι βγήκαν από συζητήσεις με πραγματικούς πελάτες ηλεκτρονικών καταστημάτων, και αφορούν ερωτήματα που οι ίδιοι είπαν ότι θα ήθελαν να απαντήσουν:

1. Ποια αντικείμενα παρουσιάζουν τις μεγαλύτερες πωλήσεις.
2. Ποιοι πελάτες πραγματοποιούν τις περισσότερες αγορές.
3. Ποιες περιοχές παρουσιάζουν τις περισσότερες πωλήσεις.
4. Ποια χρονική περίοδο συγκεντρώνονται οι πωλήσεις.
5. Σε ποια προϊόντα καταγράφονται οι περισσότερες επιστροφές.
6. Πώς κατανέμονται οι πωλήσεις ανά εύρος τιμής.
7. Πώς κατανέμονται οι πωλήσεις ανά χαρακτηριστικό προϊόντος.

Πάνω σε αυτά προστέθηκαν, σαν επέκταση της αρχικής εκφώνησης, τα οικονομικά μεγέθη που δείχνουν αν οι απαντήσεις αξίζει να αξιοποιηθούν: η ακαθάριστη αξία πωλήσεων, η επαναληπτικότητα των πελατών, η σύνθεση της ανάπτυξης και η κερδοφορία.

Πέρα από τα περιγραφικά ερωτήματα, η εργασία εφαρμόζει τρεις οικογένειες τεχνικών:

- **Εξόρυξη συχνών υποσυνόλων**, για την ανάδειξη προϊόντων με ιδιαίτερη συσχέτιση, όπως αυτή αποτυπώνεται στα δεδομένα.
- **Συσταδοποίηση σε δύο επίπεδα**, με πρώτη ομαδοποίηση ως προς την περιοχή και τον χρόνο και δεύτερη, εντός κάθε συστάδας, ως προς επιπρόσθετες παραμέτρους συμπεριφοράς.
- **Τεχνικές πρόβλεψης**, για την προβολή των πωλήσεων στο μέλλον με μετρήσιμη ακρίβεια.

1.3 Απαίτηση γενικότητας

Ο δεύτερος στόχος, εξίσου σημαντικός, είναι η γενικότητα. Το σύστημα δεν σχεδιάστηκε για ένα συγκεκριμένο κατάστημα, αλλά ώστε να μπορεί να στραφεί σε οποιοδήποτε με ελάχιστη παραμετροποίηση.

Η απαίτηση αυτή περνάει μέσα σε όλη τη σχεδίαση. Η ανάλυση δεν διαβάζει ποτέ το σχήμα δεδομένων μιας συγκεκριμένης πηγής: κάθε πηγή προσαρμόζεται σε ένα κανονικοποιημένο σχήμα, που δημοσιεύεται ως συμβόλαιο δεδομένων. Ένα κατάστημα μπορεί να στείλει τις συναλλαγές του σε αυτή τη μορφή ή να δώσει πρόσβαση ανάγνωσης στη βάση του, οπότε το να συνδεθεί είναι θέμα παραμετροποίησης και όχι γραψίματος κώδικα.

Για τον ίδιο λόγο αποφεύγονται τα απόλυτα κατώφλια όπου δεν δικαιολογούνται. Οι δείκτες λογιστικής ανάπτυξης, για παράδειγμα, είναι εξ ορισμού ανεξάρτητοι από το επιχειρηματικό μοντέλο, και το να επιβάλεις ένα σταθερό σημείο αναφοράς θα ακύρωνε ακριβώς αυτή την ιδιότητα.

1.4 Ζήτημα ειλικρίνειας των αποτελεσμάτων

Ένα σημείο περνάει μέσα από όλη την εργασία και δηλώνεται από την αρχή: η διάκριση ανάμεσα σε όσα *μετριούνται* και σε όσα *υποθέτουμε*.

Το σύνολο δεδομένων που χρησιμοποιείται καταγράφει τι πουλήθηκε και σε ποια τιμή. Δεν καταγράφει κόστος πωληθέντων ούτε δαπάνες marketing. Άρα τα ερωτήματα κερδοφορίας δεν μπορούν να απαντηθούν ως μετρήσεις, όσο χρήσιμη κι αν θα ήταν η απάντηση.

Η εργασία δεν προσπερνάει αυτόν τον περιορισμό με εύλογες εικασίες. Αντί γι' αυτό, τα μεγέθη κερδοφορίας υλοποιούνται ως ρητή ανάλυση ευαισθησίας πάνω σε δηλωμένες παραδοχές, ξεχωριστά από τα μετρήσιμα μεγέθη σε επίπεδο κώδικα, διεπαφής και παρουσίασης. Η διάκριση αυτή αναπτύσσεται στην ενότητα 7.5.

1.5 Δομή της εργασίας

Το κεφάλαιο 2 παρουσιάζει το θεωρητικό υπόβαθρο: προεπεξεργασία δεδομένων, εξόρυξη συχνών υποσυνόλων, συσταδοποίηση, ανάλυση RFM και τους οικονομικούς δείκτες του ηλεκτρονικού εμπορίου.

Το κεφάλαιο 3 περιγράφει το σύνολο δεδομένων, την αρχιτεκτονική του συστήματος, το κανονικοποιημένο σχήμα και τη διαδικασία προεπεξεργασίας.

Τα κεφάλαια 4 έως 7 παρουσιάζουν τα αποτελέσματα: περιγραφική ανάλυση, συχνά υποσύνολα, συσταδοποίηση, και τέλος πρόβλεψη μαζί με την οικονομική ανάλυση.

Το κεφάλαιο 8 συνοψίζει τα ευρήματα, τα αποτιμά ως προς την πρακτική τους αξία, δηλώνει τους περιορισμούς και προτείνει επεκτάσεις.

2. Θεωρητικό υπόβαθρο

Το κεφάλαιο παρουσιάζει τις τεχνικές που εφαρμόζονται στη συνέχεια. Η ανάπτυξη ακολουθεί κατά βάση τα κεφάλαια 2, 3, 6 και 10 του Han κ.ά. (2011).

2.1 Προεπεξεργασία δεδομένων

Τα πραγματικά δεδομένα συναλλαγών είναι σπανίως έτοιμα προς ανάλυση. Ο Han κ.ά. (2011) διακρίνει τέσσερις κατηγορίες εργασιών προεπεξεργασίας: καθαρισμό, ολοκλήρωση, μετασχηματισμό και μείωση.

Στο πλαίσιο της εργασίας, ο καθαρισμός αφορά εγγραφές που δεν μπορούν να στηρίξουν ανάλυση: μη αναγνώσιμες ημερομηνίες, ελλιπείς κωδικούς προϊόντων, μηδενικές ποσότητες και μη θετικές τιμές. Η ολοκλήρωση αφορά την αντιστοίχιση ετερογενών πηγών σε ενιαίο σχήμα, ζήτημα που στην παρούσα εργασία αντιμετωπίζεται αρχιτεκτονικά μέσω των προσαρμογέων πηγών.

Σημασία έχει η διάκριση ανάμεσα σε ελλιπή και σε μη έγκυρη τιμή. Μια πώληση χωρίς αναγνωριστικό πελάτη είναι ελλιπής αλλά έγκυρη: παραμένει πραγματική πώληση και πρέπει να μετράει στις αναλύσεις προϊόντος, περιοχής και χρόνου. Μια εγγραφή με μηδενική τιμή, από την άλλη, δεν είναι συναλλαγή αλλά λογιστική προσαρμογή, και αν την κρατούσαμε θα στρέβλωνε κάθε μέγεθος εσόδων.

Ο μετασχηματισμός περιλαμβάνει την τυποποίηση των χαρακτηριστικών πριν από τη συσταδοποίηση, ζήτημα στο οποίο επανερχόμαστε στην ενότητα 2.3.

2.2 Εξόρυξη συχνών υποσυνόλων

Η ανάλυση καλαθιού αγορών αναζητά σύνολα αντικειμένων που εμφανίζονται από κοινού σε συναλλαγές συχνότερα από ό,τι θα αναμενόταν τυχαία.

2.2.1 Ορισμοί

Έστω I το σύνολο των διαθέσιμων αντικειμένων και D το σύνολο των συναλλαγών, όπου κάθε συναλλαγή $T \subseteq I$. Για ένα υποσύνολο $X \subseteq I$, η *υποστήριξη* ορίζεται ως το ποσοστό των συναλλαγών που το περιέχουν:

$$\text{support}(X) = \frac{|\{T \in D : X \subseteq T\}|}{|D|} \tag{2.1}$$

Ένα υποσύνολο χαρακτηρίζεται *συχνό* όταν η υποστήριξή του υπερβαίνει ένα προκαθορισμένο κατώφλι.

Για έναν κανόνα $X \Rightarrow Y$ με $X \cap Y = \emptyset$, η *εμπιστοσύνη* εκφράζει την υπό συνθήκη πιθανότητα:

$$\text{confidence}(X \Rightarrow Y) = \frac{\text{support}(X \cup Y)}{\text{support}(X)} \tag{2.2}$$

2.2.2 Το μέτρο της άρσης

Η εμπιστοσύνη από μόνη της είναι παραπλανητική. Αν το Y εμφανίζεται σχεδόν σε κάθε συναλλαγή, τότε κάθε κανόνας με επακόλουθο το Y θα έχει υψηλή εμπιστοσύνη, χωρίς να υφίσταται καμία πραγματική συσχέτιση.

Η *άρση* διορθώνει ακριβώς αυτό, κανονικοποιώντας ως προς τη συχνότητα του επακόλουθου:

$$\text{lift}(X \Rightarrow Y) = \frac{\text{confidence}(X \Rightarrow Y)}{\text{support}(Y)} \tag{2.3}$$

Τιμή μεγαλύτερη της μονάδας δηλώνει συνεμφάνιση ισχυρότερη από όσο προβλέπει η στατιστική ανεξαρτησία, τιμή ίση με τη μονάδα δηλώνει ανεξαρτησία, και τιμή μικρότερη δηλώνει αρνητική συσχέτιση.

2.2.3 Αλγόριθμοι

Ο Apriori (Agrawal & Srikant, 1994) αξιοποιεί την ιδιότητα του κλειστού προς τα κάτω: κάθε υποσύνολο ενός συχνού συνόλου είναι επίσης συχνό, επομένως ένα υποψήφιο σύνολο μπορεί να απορριφθεί χωρίς έλεγχο αν κάποιο υποσύνολό του δεν είναι συχνό. Ο αλγόριθμος προχωρά ανά επίπεδο, απαιτώντας πολλαπλές διελεύσεις της βάσης.

Ο FP-Growth (Han κ.ά., 2000) κατασκευάζει συμπιεσμένο δένδρο προθεμάτων και εξάγει τα συχνά σύνολα αναδρομικά, αποφεύγοντας εντελώς τη δημιουργία υποψηφίων. Για το ίδιο κατώφλι υποστήριξης, τα δύο αποτελέσματα είναι ταυτόσημα· η διαφορά τους είναι υπολογιστική.

2.3 Συσταδοποίηση

Η συσταδοποίηση ομαδοποιεί παρατηρήσεις ώστε οι εντός της ίδιας ομάδας να είναι περισσότερο όμοιες μεταξύ τους παρά με τις υπόλοιπες.

2.3.1 Ο αλγόριθμος k-means

Ο k-means (MacQueen, 1967) ελαχιστοποιεί το άθροισμα των τετραγωνικών αποστάσεων κάθε σημείου από το κέντρο της συστάδας του:

$$J = \sum_{i=1}^{k} \sum_{x \in C_i} \|x - \mu_i\|^2 \tag{2.4}$$

Η μέθοδος προϋποθέτει ότι οι αποστάσεις είναι συγκρίσιμες μεταξύ των διαστάσεων. Χαρακτηριστικά διαφορετικής κλίμακας παραβιάζουν την προϋπόθεση αυτή: ένα μέγεθος μετρημένο σε νομισματικές μονάδες κυριαρχεί έναντι ενός μετρημένου σε πλήθη αποκλειστικά λόγω της τάξης μεγέθους του. Η τυποποίηση των χαρακτηριστικών πριν τη συσταδοποίηση δεν αποτελεί επομένως προαιρετική βελτίωση αλλά προϋπόθεση ορθότητας.

2.3.2 Αξιολόγηση με τον δείκτη περιγράμματος

Ο δείκτης περιγράμματος (Rousseeuw, 1987) αποτιμά την ποιότητα μιας κατάτμησης χωρίς γνώση της πραγματικής ομαδοποίησης. Για κάθε σημείο i, με $a(i)$ τη μέση απόσταση από τα σημεία της ίδιας συστάδας και $b(i)$ τη μέση απόσταση από τα σημεία της πλησιέστερης άλλης συστάδας:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \tag{2.5}$$

Ο δείκτης λαμβάνει τιμές στο $[-1, 1]$. Ο μέσος όρος επί όλων των σημείων χρησιμοποιείται εδώ για την επιλογή του πλήθους των συστάδων, αντί αυτό να οριστεί εκ των προτέρων.

2.3.3 Ιεραρχική, εμφωλευμένη ομαδοποίηση

Η προσέγγιση που ακολουθείται δεν είναι η κλασική ιεραρχική συσταδοποίηση αλλά η διαδοχική εφαρμογή κατατμήσεων σε δύο επίπεδα, με διαφορετικά χαρακτηριστικά σε κάθε επίπεδο. Η δομή αυτή επιτρέπει την εξαγωγή διαφορετικού τύπου πληροφορίας από κάθε επίπεδο του δένδρου, και αναπτύσσεται στο κεφάλαιο 6.

2.4 Ανάλυση RFM και τμηματοποίηση πελατών

Το μοντέλο RFM περιγράφει κάθε πελάτη με τρία μεγέθη: την προσφατότητα της τελευταίας του αγοράς, τη συχνότητα των αγορών του και τη χρηματική τους αξία. Η απλό-

τητά του και η άμεση ερμηνευσιμότητά του το καθιστούν διαδεδομένο στη βιομηχανία.

Οι Chen κ.ά. (2012) εφαρμόζουν RFM σε συνδυασμό με συσταδοποίηση σε δεδομένα ηλεκτρονικού λιανικού εμπορίου, χρησιμοποιώντας το ίδιο σύνολο δεδομένων με την παρούσα εργασία. Η προσέγγιση αυτή αποτελεί τη βάση της συσταδοποίησης δεύτερου επιπέδου.

Επισημαίνεται ότι η χρηματική διάσταση του RFM αποτελεί *παρατηρούμενη* αξία μέχρι σήμερα και όχι πρόβλεψη αξίας διάρκειας ζωής. Η σύγχυση των δύο είναι συνήθης και οδηγεί σε υπερεκτίμηση.

2.5 Οικονομικοί δείκτες ηλεκτρονικού εμπορίου

2.5.1 Μετρήσιμα μεγέθη

Η ακαθάριστη αξία πωλήσεων, το ποσοστό επαναληπτικών αγορών και η διατήρηση πελατών ανά κοόρτη υπολογίζονται απευθείας από τα δεδομένα συναλλαγών.

Η λογιστική ανάπτυξης προχωρά ένα βήμα παραπέρα, αποσυνθέτοντας τη μεταβολή των εσόδων σε έξι ροές: νέα, αναβιωμένα, διατηρημένα, επέκταση, συρρίκνωση και απώλεια. Οι ροές αυτές ικανοποιούν λογιστικές ταυτότητες που επιτρέπουν την επαλήθευση της ορθότητας του υπολογισμού, και είναι ανεξάρτητες από το επιχειρηματικό μοντέλο.

2.5.2 Μεγέθη που απαιτούν παραδοχές

Η αξία διάρκειας ζωής του πελάτη (CLV), το κόστος απόκτησης πελάτη (CAC) και ο λόγος τους απαιτούν γνώση του περιθωρίου κέρδους και των δαπανών marketing. Τα μεγέθη αυτά δεν περιέχονται στα δεδομένα συναλλαγών.

Η βιβλιογραφία της πρακτικής (Croll & Yoskovitz, 2013) τα θεωρεί θεμελιώδη για την αξιολόγηση μιας επιχείρησης. Η εργασία τα υπολογίζει, αλλά μόνο ως ανάλυση ευαισθησίας πάνω σε ρητά δηλωμένες παραδοχές, ποτέ ως μετρήσεις.

3. Μεθοδολογία

3.1 Το σύνολο δεδομένων

Χρησιμοποιείται το σύνολο δεδομένων Online Retail II του αποθετηρίου UCI, το οποίο καταγράφει τις συναλλαγές βρετανικού ηλεκτρονικού καταστήματος χονδρικής πώλησης ειδών δώρων για την περίοδο 2009-2011.

Η επιλογή του στηρίχθηκε σε τρία κριτήρια. Είναι δημόσιο, επομένως τα αποτελέσματα είναι αναπαραγώγιμα και ελέγξιμα. Αποτελεί το σύνολο δεδομένων της εργασίας των Chen κ.ά. (2012), γεγονός που επιτρέπει τη σύγκριση με δημοσιευμένη έρευνα. Τέλος, περιέχει ακυρωμένα παραστατικά, χωρίς τα οποία το ερώτημα των επιστροφών δεν θα ήταν απαντήσιμο.

3.1.1 Δομή των εγγραφών

Κάθε εγγραφή αντιστοιχεί σε μία γραμμή προϊόντος εντός ενός παραστατικού και περιλαμβάνει αναγνωριστικό παραστατικού, κωδικό προϊόντος, περιγραφή, ποσότητα, ημερομηνία, τιμή μονάδας, αναγνωριστικό πελάτη και χώρα.

Τα δύο διαθέσιμα φύλλα δεν χρησιμοποιούν τα ίδια ονόματα στηλών. Ο προσαρμογέας που υλοποιήθηκε δέχεται και τις δύο ονοματοδοσίες, ώστε οποιαδήποτε έκδοση του συνόλου δεδομένων να λειτουργεί χωρίς τροποποίηση.

3.1.2 Μεγέθη του συνόλου δεδομένων μετά την εισαγωγή

Το αρχείο περιέχει 1.067.371 γραμμές συνολικά και στα δύο φύλλα. Μετά την προεπεξεργασία και την εισαγωγή προκύπτουν τα μεγέθη του Πίνακα 3.1.

Οντότητα	Πλήθος
Παραγγελίες	39.516
Γραμμές παραγγελιών	1.002.423
Επιστροφές	17.925
Πελάτες	5.875
Προϊόντα	4.900
Περιοχές	43

Πίνακας 3.1: Μεγέθη μετά την εισαγωγή του συνόλου δεδομένων

Η εισαγωγή ολοκληρώνεται σε περίπου 140 δευτερόλεπτα. Η αρχική υλοποίηση έγραφε μία μία τις γραμμές και τις ξαναδιάβαζε αμέσως, κάτι που σήμαινε δύο πηγαινέλα στη βάση ανά εγγραφή και έκανε την εισαγωγή ενός εκατομμυρίου γραμμών πρακτικά ανέφικτη. Το πρόβλημα λύθηκε φτιάχνοντας τα αντικείμενα κατευθείαν, αφού το πρωτεύον κλειδί το παράγει η ίδια η εφαρμογή, μαζί με γράψιμο ανά παρτίδα.

3.1.3 Διαχείριση μη εμπορικών κωδικών

Κατά την πρώτη ανάλυση του πλήρους συνόλου δεδομένων διαπιστώθηκε ότι οι κορυφαίες θέσεις της κατάταξης προϊόντων δεν καταλαμβάνονταν από εμπορεύματα. Οι κωδικοί M (χειροκίνητη προσαρμογή) και DOT (ταχυδρομικά τέλη) κατείχαν την πρώτη και την τρίτη θέση αντίστοιχα, ενώ στην ανάλυση επιστροφών ο κωδικός M υπερέβαινε σε αξία κάθε πραγματικό προϊόν.

Το σύνολο δεδομένων καταγράφει ταχυδρομικά τέλη, χειροκίνητες προσαρμογές, προμήθειες πλατφορμών, δείγματα, εκπτώσεις, τραπεζικά έξοδα, δωροεπιταγές και τουλάχιστον μία δοκιμαστική εγγραφή με την ίδια μορφή που καταγράφει τα εμπορεύματα.

Οι κωδικοί αυτοί δεν μπορούν να απομονωθούν με κανόνα μορφής. Ορισμένοι πραγματικοί κωδικοί προϊόντων είναι αλφαριθμητικοί, όπως η σειρά DCGS η οποία αντιστοιχεί σε υπαρκτά εμπορεύματα, επομένως ένα φίλτρο βασισμένο σε μοτίβο θα απέρριπτε έγκυρα δεδομένα. Για τον λόγο αυτό χρησιμοποιείται ρητός κατάλογος αποκλεισμού, παραμετροποιήσιμος ανά πηγή.

Οι δωροεπιταγές αποκλείονται και αυτές: είναι μέσο πληρωμής, και αν μετρήσουμε και την επιταγή και τα αγαθά που αγοράστηκαν με αυτήν, μετράμε δύο φορές το ίδιο πράγμα.

Ο αποκλεισμός αφαιρεί περίπου το 4% των εσόδων, αλλά μεταβάλλει ποιοτικά το αποτέλεσμα: η κατάταξη προϊόντων και η ανάλυση επιστροφών αποκτούν εμπορικό νόημα.

3.1.4 Δηλωμένοι περιορισμοί

Το σύνολο δεδομένων επιβάλλει τρεις περιορισμούς που καθορίζουν τη σχεδίαση και δηλώνονται ρητά:

- Δεν περιέχει κόστος πωληθέντων ούτε δαπάνες marketing.
- Δεν περιέχει δομημένη κατηγοριοποίηση προϊόντων, παρά μόνο ελεύθερο κείμενο περιγραφής.
- Η γεωγραφική πληροφορία περιορίζεται σε επίπεδο χώρας.

3.2 Αρχιτεκτονική του συστήματος

Το σύστημα υλοποιήθηκε ως εφαρμογή FastAPI με βάση δεδομένων PostgreSQL και ουρά εργασιών Celery. Η δομή του είναι στρωματωμένη: διεπαφή, υπηρεσίες, αποθετήρια και μοντέλα.

Οι αλγόριθμοι εξόρυξης και μηχανικής μάθησης υλοποιούνται σε ξεχωριστό επίπεδο, χωρίς καμία εξάρτηση από τη βάση δεδομένων ή το πλαίσιο της εφαρμογής. Δέχονται απλές δομές δεδομένων και επιστρέφουν απλές δομές δεδομένων.

Ο διαχωρισμός αυτός δεν είναι θέμα αισθητικής. Επιτρέπει να ελέγχονται οι αλγόριθμοι με δεδομένα φτιαγμένα έτσι ώστε το αναμενόμενο αποτέλεσμα να βγαίνει με το χέρι, κάτι αδύνατο αν οι αλγόριθμοι διάβαζαν κατευθείαν από τη βάση, και κάνει τον ίδιο κώδικα να τρέχει αυτούσιος μέσα από σημειωματάρια Jupyter.

Οι χρονοβόρες αναλύσεις εκτελούνται ασύγχρονα σε εργάτες, καθώς η εξόρυξη συχνών υποσυνόλων σε πλήρες ιστορικό λιανικής υπερβαίνει κατά πολύ τη διάρκεια ζωής ενός αιτήματος.

3.3 Κανονικοποιημένο σχήμα δεδομένων

Οι αναλύσεις δεν διαβάζουν ποτέ το σχήμα μιας συγκεκριμένης πηγής. Κάθε πηγή αντιστοιχίζεται σε κοινό σχήμα έξι οντοτήτων: πελάτης, προϊόν, περιοχή, παραγγελία, γραμμή παραγγελίας και επιστροφή.

Τρεις σχεδιαστικές αποφάσεις αξίζουν αναφοράς.

3.3.1 Η περιοχή αποθηκεύεται στην παραγγελία

Η περιοχή στην οποία έγινε μια πώληση είναι ιδιότητα της πώλησης και όχι μόνο του πελάτη. Αποθηκεύοντάς την στην παραγγελία, τα αποτελέσματα μένουν σωστά ακόμη κι αν η περιοχή ενός πελάτη διορθωθεί αργότερα, και το συχνότερο ερώτημα της εργασίας γλιτώνει μια σύζευξη.

3.3.2 Οι επιστροφές είναι αυτοτελείς εγγραφές

Οι επιστροφές καταγράφονται ως ξεχωριστές εγγραφές με θετικά μεγέθη, και όχι ως αρνητικές γραμμές παραγγελίας.

Είναι η πιο καθοριστική απόφαση μοντελοποίησης της εργασίας: κάνει δομικά αδύνατο να αφαιρεθούν σιωπηρά οι επιστροφές από τα έσοδα. Έσοδα και επιστροφές μετριούνται ξεχωριστά σε κάθε ανάλυση.

3.3.3 Η τιμή αποθηκεύεται ανά γραμμή

Το ίδιο προϊόν πωλείται σε διαφορετικές τιμές στο πέρασμα του χρόνου. Η τιμή που χρεώθηκε αποθηκεύεται στη γραμμή της παραγγελίας, και η κατηγοριοποίηση ανά εύρος τιμής εφαρμόζεται σε αυτήν, ώστε κάθε πώληση να προσμετράται εκεί όπου πράγματι πραγματοποιήθηκε.

3.4 Προσαρμογείς πηγών δεδομένων

Η διεπαφή ενός προσαρμογέα συνίσταται σε μία μέθοδο, η οποία παράγει ροή κανονικοποιημένων εγγραφών. Η προσάρτηση νέου καταστήματος δεν επιφέρει καμία απολύτως αλλαγή στον αναλυτικό κώδικα.

Οι προσαρμογείς είναι σκοπίμως απλοϊκοί: μεταφέρουν το πρόσημο της ποσότητας όπως το βρίσκουν, χωρίς να ερμηνεύουν τι σημαίνει. Η ερμηνεία ανήκει στην υπηρεσία εισαγωγής, ώστε να εφαρμόζεται ταυτόσημα σε κάθε πηγή.

3.4.1 Τρεις οδοί παράδοσης δεδομένων

Η απαίτηση γενικότητας δεν ικανοποιείται από τη δυνατότητα συγγραφής προσαρμογέα, εφόσον αυτή προϋποθέτει προγραμματιστική εργασία για κάθε νέο κατάστημα. Για τον λόγο αυτό η ίδια κανονικοποιημένη εγγραφή δημοσιεύεται ως συμβόλαιο δεδομένων και υποστηρίζονται τρεις οδοί παράδοσης:

- **Αρχείο**: το κατάστημα εξάγει, το σύστημα διαβάζει. Είναι η μόνη οδός που απαιτεί κώδικα, και μόνο επειδή οι μορφές αρχείων ποικίλλουν απεριόριστα.
- **Διεπαφή προγραμματισμού**: το κατάστημα αποστέλλει παρτίδες εγγραφών σε κανονικοποιημένη μορφή. Δεν γράφεται κώδικας.
- **Βάση δεδομένων**: το σύστημα διαβάζει απευθείας από τη βάση του καταστήματος, με βάση ένα ερώτημα και μια αντιστοίχιση στηλών προς τα κανονικοποιημένα πεδία. Ούτε εδώ γράφεται κώδικας.

Η αντιστοίχιση των στηλών δηλώνεται ρητά και δεν συνάγεται από την ονομασία τους. Η αυτόματη αναγνώριση λειτουργεί έως την ημέρα που θα ταιριάξει σιωπηλά με λανθασμένη στήλη, και μια εσφαλμένη αντιστοίχιση κοστίζει ασυγκρίτως περισσότερο από μια απούσα. Για τον ίδιο λόγο, ένα κανονικοποιημένο πεδίο γραμμένο λανθασμένα στην αντιστοίχιση θεωρείται σφάλμα και όχι παράλειψη.

Κρίσιμο σημείο είναι ότι οι κανόνες εγκυρότητας υλοποιούνται μία φορά και εφαρμόζονται και στις τρεις οδούς. Κανόνας υλοποιημένος ανά πηγή είναι κανόνας που τελικά

αποκλίνει ανά πηγή, οπότε δύο καταστήματα με τα ίδια δεδομένα θα λάμβαναν διαφορετικές απαντήσεις.

Η γενικότητα ελέγχεται και δεν απλώς δηλώνεται: η ανάγνωση από βάση δεδομένων δοκιμάζεται πάνω σε σχήμα καταστήματος που δεν έχει κοινή στήλη, κοινή ονομασία ούτε κοινό σύστημα βάσης με το σύνολο δεδομένων των κεφαλαίων αποτελεσμάτων. Η γενικότητα που τεκμηριώνεται από τη σχεδίαση αποτελεί επιχείρημα· η γενικότητα που ασκείται σε άσχετη πηγή αποτελεί τεκμήριο.

3.5 Προεπεξεργασία

Εγγραφές απορρίπτονται, με καταγραφή του λόγου και του πλήθους, όταν δεν μπορούν να στηρίξουν ανάλυση: μη αναγνώσιμη ημερομηνία ή ποσότητα, απουσία κωδικού προϊόντος, μηδενική ποσότητα, μη θετική τιμή.

Η απόρριψη των μη θετικών τιμών θέλει εξήγηση. Στο συγκεκριμένο σύνολο δεδομένων οι εγγραφές αυτές είναι προσαρμογές αποθέματος και διαγραφές επισφαλών απαιτήσεων, όχι εμπορικές συναλλαγές, και αν τις κρατούσαμε θα στρέβλωναν κάθε μέγεθος εσόδων.

Οι εγγραφές χωρίς αναγνωριστικό πελάτη, από την άλλη, *κρατιούνται*. Είναι σημαντικό ποσοστό του συνόλου και παραμένουν πραγματικές πωλήσεις. Βγαίνουν έξω μόνο από τις αναλύσεις που θέλουν απόδοση σε πρόσωπο, και κάθε φορά ρητά.

3.6 Επαλήθευση της υλοποίησης

Το ότι οι υπολογισμοί βγάζουν σωστά αποτελέσματα δεν το δείχνει ο ίδιος ο κώδικας, το δείχνουν αυτοματοποιημένοι έλεγχοι.

Όπου το αποτέλεσμα είναι αριθμητικά προσδιορισμένο, ελέγχεται η ακριβής τιμή του πάνω σε δεδομένα που βγαίνουν με το χέρι. Όπου υπάρχει μαθηματική ταυτότητα, όπως στη λογιστική ανάπτυξης, η ταυτότητα επαληθεύεται άμεσα, τόσο σε συνθετικά όσο και σε πραγματικά δεδομένα. Όπου μια ιδιότητα είναι κρίσιμη, όπως η τυποποίηση πριν τη συσταδοποίηση, κατασκευάζεται έλεγχος που αποτυγχάνει αν η ιδιότητα αφαιρεθεί.

4. Περιγραφική ανάλυση δεδομένων

Το κεφάλαιο απαντά στα επτά ερωτήματα που τέθηκαν από την πλευρά της επιχείρησης. Όλα τα μεγέθη υπολογίζονται με συναθροίσεις πάνω στο κανονικοποιημένο σχήμα του κεφαλαίου 3, μέσα στη βάση δεδομένων και όχι στη μνήμη της εφαρμογής, ώστε η ανάλυση να παραμένει εφικτή καθώς ο όγκος των συναλλαγών αυξάνεται.

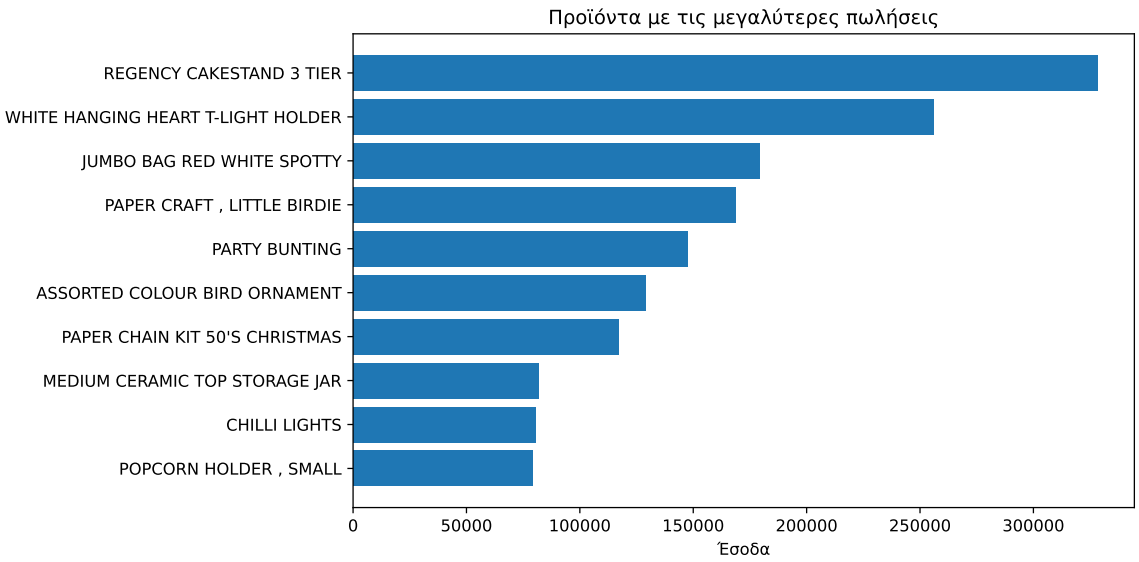
Οι ίδιες συναρτήσεις τροφοδοτούν και τα σημεία πρόσβασης του API, επομένως τα νούμερα της εργασίας και τα νούμερα του συστήματος δεν μπορούν να αποκλίνουν.

4.1 Αντικείμενα με τις μεγαλύτερες πωλήσεις

Η κατάταξη γίνεται ως προς τα έσοδα και όχι ως προς τις μονάδες. Ένα προϊόν χαμηλής τιμής με μεγάλο όγκο και ένα προϊόν υψηλής τιμής με μικρό όγκο απαντούν σε διαφορετικά ερωτήματα, και για τις αποφάσεις marketing η αξία υπερτερεί της ποσότητας.

Κωδικός	Περιγραφή	Μονάδες	Έσοδα
22423	REGENCY CAKESTAND 3 TIER	26.315	328.112
85123A	WHITE HANGING HEART T-LIGHT HOLDER	93.497	255.784
85099B	JUMBO BAG RED WHITE SPOTTY	96.243	179.433
23843	PAPER CRAFT , LITTLE BIRDIE	80.995	168.470
47566	PARTY BUNTING	28.022	147.455
84879	ASSORTED COLOUR BIRD ORNAMENT	79.898	128.941
22086	PAPER CHAIN KIT 50’S CHRISTMAS	34.907	117.033

Πίνακας 4.1: Προϊόντα με τα υψηλότερα έσοδα



Εικόνα 4.1: Προϊόντα με τα υψηλότερα έσοδα

Η διάκριση αξίας και ποσότητας είναι εμφανής στα δεδομένα. Το REGENCY CAKESTAND κατέχει την πρώτη θέση σε έσοδα με 26.315 μονάδες, ενώ το JUMBO BAG πωλεί σχεδόν τετραπλάσιες μονάδες (96.243) και κατατάσσεται τρίτο. Μια κατάταξη ως προς τις μονάδες θα αντέστρεφε τη σειρά και θα οδηγούσε σε διαφορετικές εμπορικές αποφάσεις.

Σημειώνεται ότι τα αποτελέσματα αυτά προκύπτουν μετά τον αποκλεισμό των μη εμπορικών κωδικών της ενότητας 3.1.3. Χωρίς αυτόν, τις δύο από τις τρεις πρώτες θέσεις καταλάμβαναν χειροκίνητες προσαρμογές και ταχυδρομικά τέλη.

4.2 Πελάτες με τις περισσότερες αγορές

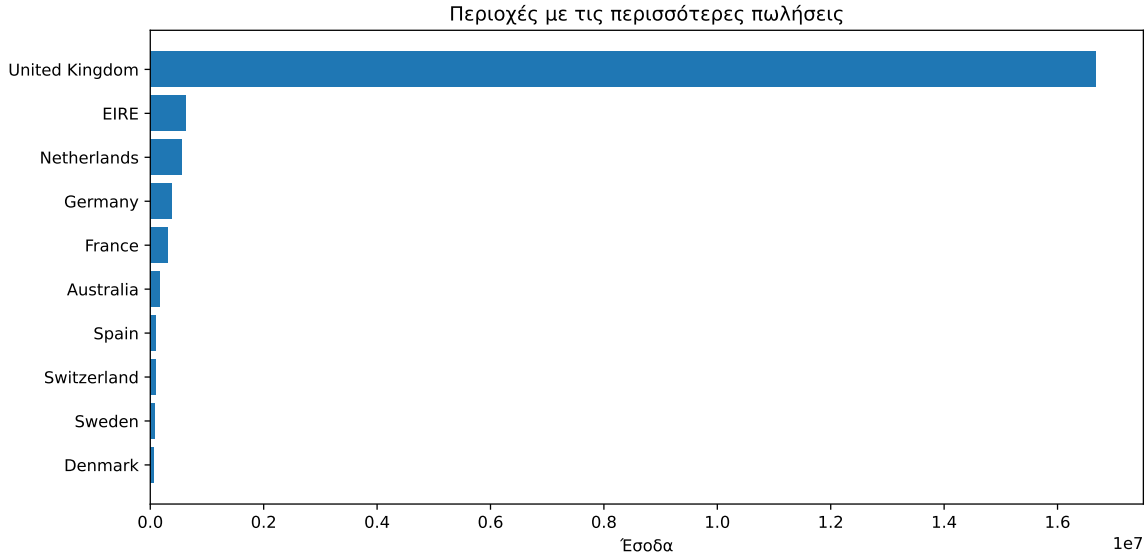
Στην ανάλυση αυτή, και μόνο σε αυτήν, εξαιρούνται οι πωλήσεις χωρίς αναγνωριστικό πελάτη. Αποτελούν σημαντικό ποσοστό του συνόλου δεδομένων και παραμένουν πραγματικές πωλήσεις, οπότε συμμετέχουν κανονικά σε κάθε άλλη ανάλυση. Ο περιορισμός αναφέρεται ρητά, ώστε τα αθροίσματα ανά πελάτη να μην συγκρίνονται λανθασμένα με τα συνολικά έσοδα.

4.3 Περιοχές με τις περισσότερες πωλήσεις

Περιοχή	Παραγγελίες	Πελάτες	Έσοδα
United Kingdom	36.184	5.334	16.679.730
EIRE	581	3	618.511
Netherlands	216	22	549.775
Germany	753	107	379.438
France	598	93	308.164
Australia	89	15	167.652

Πίνακας 4.2: Περιοχές με τα υψηλότερα έσοδα

Όπως και στην κατάταξη προϊόντων, τα μεγέθη του πίνακα προκύπτουν μετά τον αποκλεισμό των μη εμπορικών κωδικών της ενότητας 3.1.3. Ο αποκλεισμός βαραίνει δυσανάλογα τις αγορές εξαγωγής, όπου τα ταχυδρομικά τέλη τιμολογούνται ως ξεχωριστές γραμμές, ενώ αφήνει την εγχώρια αγορά σχεδόν ανέπαφη. Στην Ιρλανδία μάλιστα δύο από τα πέντε αναγνωριστικά πελάτη εμφανίζονται αποκλειστικά σε τέτοιες γραμμές, οπότε δεν αντιστοιχούν σε πελάτες που αγόρασαν εμπόρευμα.



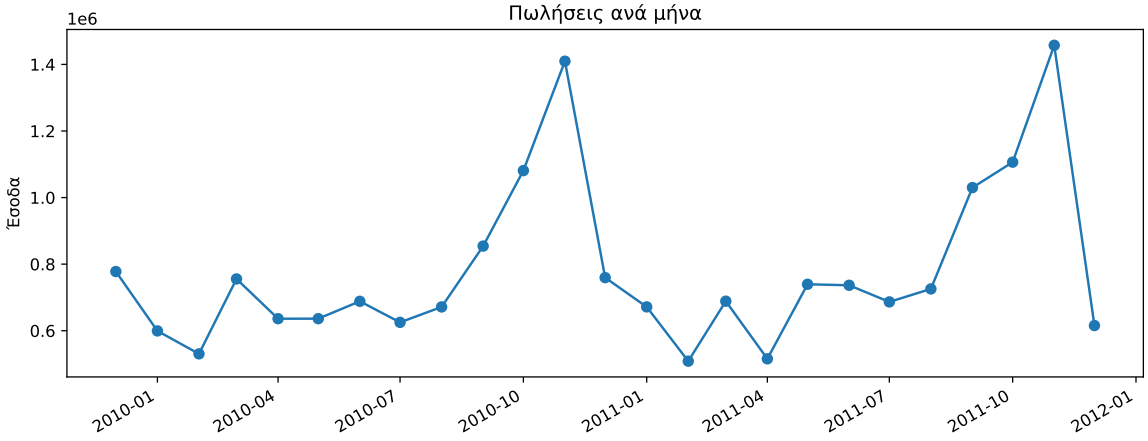
Εικόνα 4.2: Περιοχές με τα υψηλότερα έσοδα

Η κατανομή είναι ακραία ασύμμετρη: η εγχώρια αγορά συγκεντρώνει περίπου το 86% των εσόδων. Αξιοσημείωτη είναι η περίπτωση της Ιρλανδίας, όπου τρεις μόνο πελάτες παράγουν έσοδα υψηλότερα από τους 107 πελάτες της Γερμανίας, ένδειξη χονδρικής σχέσης και όχι λιανικής. Η παρατήρηση αυτή επανεμφανίζεται ποσοτικοποιημένη στη συσταδοποίηση του κεφαλαίου 6.

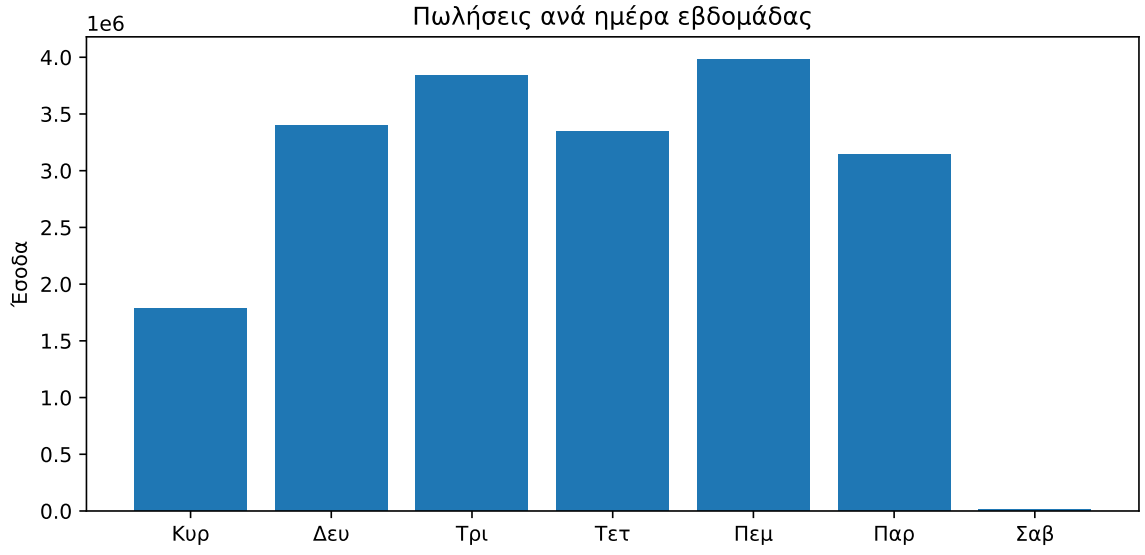
Η περιοχή αποθηκεύεται στην ίδια την παραγγελία και όχι μόνο στον πελάτη. Η περιοχή στην οποία πραγματοποιήθηκε μια πώληση αποτελεί ιδιότητα της πώλησης, και η επιλογή αυτή διατηρεί τα αποτελέσματα ορθά ακόμη και αν η περιοχή ενός πελάτη διορθωθεί αργότερα.

4.4 Χρονική κατανομή των πωλήσεων

Εξετάζονται δύο συμπληρωματικές όψεις. Η πρώτη είναι η κατανομή σε ημερολογιακά διαστήματα, με ρυθμιζόμενη ανάλυση από την ημέρα έως το έτος. Η δεύτερη είναι η κατανομή ανά ημέρα της εβδομάδας, η οποία αναδεικνύει εβδομαδιαία περιοδικότητα που τα ημερολογιακά διαστήματα αποκρύπτουν.



Εικόνα 4.3: Μηνιαία κατανομή των εσόδων. Η κορύφωση του Νοεμβρίου επαναλαμβάνεται και στα δύο έτη, ενώ ο τελευταίος μήνας είναι ημιτελής



Εικόνα 4.4: Κατανομή των εσόδων ανά ημέρα της εβδομάδας

Η ανάλυση αυτή τροφοδοτεί επίσης το κεφάλαιο της πρόβλεψης, όπου η χρονοσειρά των εσόδων χρησιμοποιείται για εκπαίδευση και έλεγχο.

4.5 Προϊόντα με τις περισσότερες επιστροφές

Κωδικός	Περιγραφή	Μονάδες	Αξία
23843	PAPER CRAFT , LITTLE BIRDIE	80.995	168.470
23166	MEDIUM CERAMIC TOP STORAGE JAR	74.494	77.480
22423	REGENCY CAKESTAND 3 TIER	1.452	16.571
85123A	WHITE HANGING HEART T-LIGHT HOLDER	3.636	9.384

Πίνακας 4.3: Προϊόντα με την υψηλότερη αξία επιστροφών

Δύο παρατηρήσεις είναι ουσιώδεις. Πρώτον, το προϊόν 23843 εμφανίζει επιστροφές ίσες με το σύνολο των πωλήσεών του, δηλαδή 80.995 μονάδες και στις δύο αναλύσεις. Πρόκειται για μία μεγάλη παραγγελία και την πλήρη ακύρωσή της, όχι για συστηματικό πρόβλημα ποιότητας· η διάκριση αυτή είναι ορατή μόνο επειδή πωλήσεις και επιστροφές παραμένουν χωριστά μετρήσιμες.

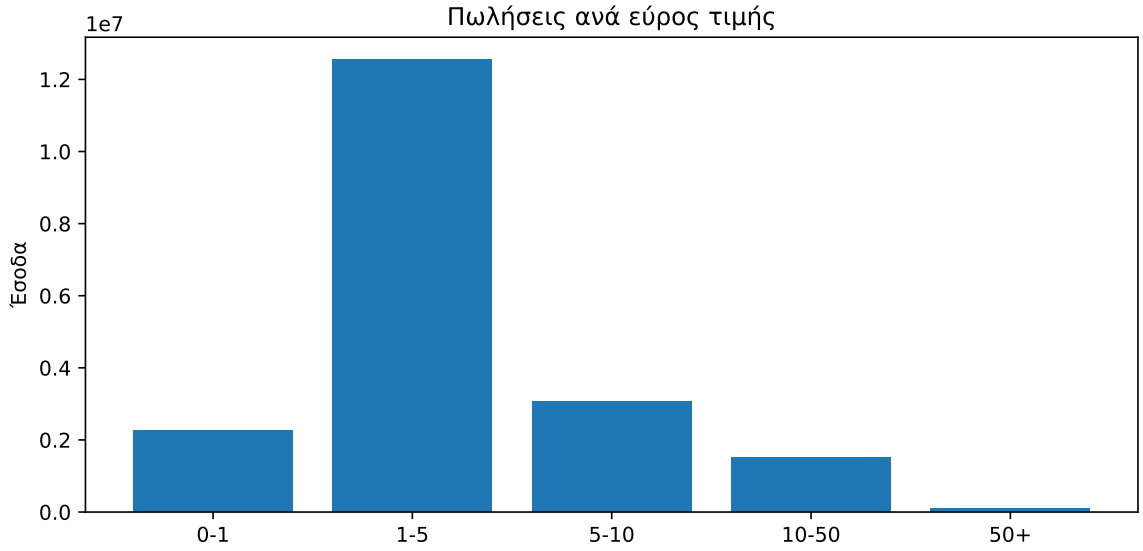
Δεύτερον, τα προϊόντα με τις υψηλότερες επιστροφές είναι σε μεγάλο βαθμό και προϊόντα με υψηλές πωλήσεις. Η απόλυτη αξία επιστροφών χωρίς αναφορά στον όγκο πωλήσεων είναι επομένως παραπλανητική· το ενδιαφέρον μέγεθος για τη λήψη αποφάσεων είναι ο λόγος των δύο.

Οι επιστροφές καταγράφονται ως αυτοτελείς εγγραφές με θετικά μεγέθη, και όχι ως αρνητικές γραμμές παραγγελίας. Έτσι οι επιστροφές δεν αφαιρούνται σιωπηρά από τα έσοδα: τα δύο μεγέθη παραμένουν ανεξάρτητα μετρήσιμα, και το ποσοστό επιστροφών ανά προϊόν υπολογίζεται χωρίς αμφισημία.

4.6 Πωλήσεις ανά εύρος τιμής

Εύρος τιμής	Γραμμές	Μονάδες	Έσοδα
0–1	199.635	4.620.313	2.252.508
1–5	632.902	5.965.662	12.542.723
5–10	126.419	433.723	3.078.865
10–50	43.034	109.177	1.521.244
50+	433	725	110.899

Πίνακας 4.4: Πωλήσεις ανά εύρος τιμής μονάδας



Εικόνα 4.5: Έσοδα ανά εύρος τιμής μονάδας

Το εύρος 1–5 κυριαρχεί, συγκεντρώνοντας περίπου το 64% των εσόδων. Στο άλλο άκρο, μόλις 433 γραμμές με τιμή άνω των 50 παράγουν 110.899, λιγότερο από το 1% των συνολικών εσόδων, ένδειξη ότι η ουρά υψηλής τιμής είναι αμελητέα τόσο αριθμητικά όσο και οικονομικά.

Η κατηγοριοποίηση εφαρμόζεται στην τιμή που πράγματι χρεώθηκε στη γραμμή της παραγγελίας και όχι στην τρέχουσα τιμή του προϊόντος. Ένα προϊόν που άλλαξε εύρος τιμής μέσα στο χρόνο προσμετράται εκεί όπου πωλήθηκε.

Τα εύρη καλύπτουν πλήρως το πεδίο τιμών, με ανοιχτό το τελευταίο, επομένως το άθροισμα των εσόδων ανά εύρος ισούται με τα συνολικά έσοδα. Η ιδιότητα αυτή ελέγχεται αυτόματα στη σουίτα ελέγχων.

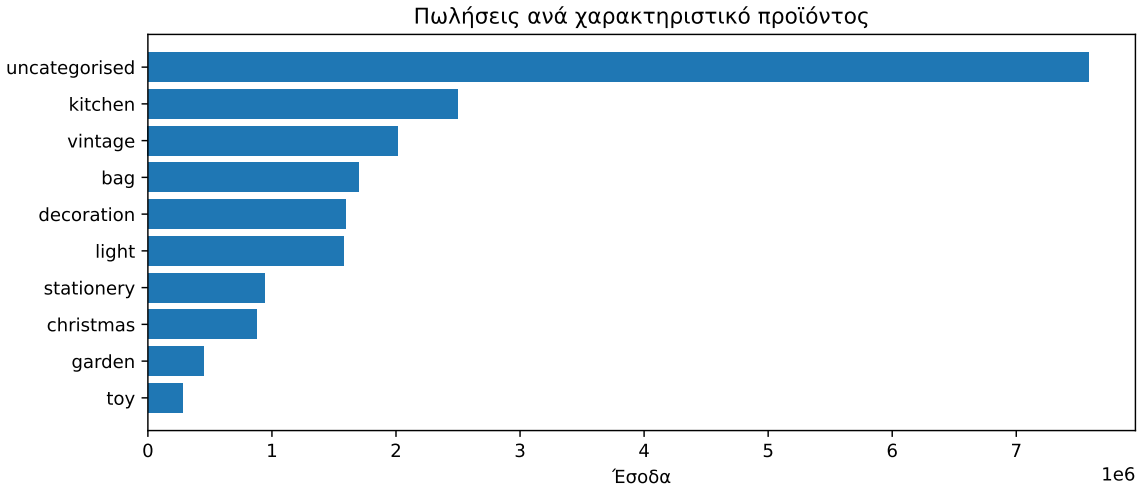
4.7 Πωλήσεις ανά χαρακτηριστικό προϊόντος

Το συγκεκριμένο σύνολο δεδομένων δεν διαθέτει δομημένη κατηγοριοποίηση προϊόντων, παρά μόνο ελεύθερο κείμενο περιγραφής. Τα χαρακτηριστικά προκύπτουν επομένως με κανόνες λέξεων-κλειδιών.

Πρόκειται για δηλωμένο περιορισμό και όχι για μεθοδολογική προτίμηση. Κάθε προϊόν αποδίδεται στην πρώτη ομάδα λέξεων-κλειδιών με την οποία ταιριάζει, ώστε τα αθροίσματα να μην διπλομετρώνται, και όσα δεν ταιριάζουν πουθενά αναφέρονται ως uncategorised αντί να αποσιωπηθούν. Το ποσοστό των εσόδων που καταλήγει σε αυτή την κατηγορία αποτελεί το ειλικρινές μέτρο της ακρίβειας της μεθόδου.

Χαρακτηριστικό	Έσοδα	Μερίδιο
uncategorised	7.581.476	38,9%
kitchen	2.493.064	12,8%
vintage	2.016.650	10,3%
bag	1.698.624	8,7%
decoration	1.592.862	8,2%
light	1.578.279	8,1%
stationery	941.026	4,8%
christmas	873.938	4,5%
garden	448.444	2,3%
toy	281.878	1,4%

Πίνακας 4.5: Πωλήσεις ανά χαρακτηριστικό προϊόντος



Εικόνα 4.6: Έσοδα ανά χαρακτηριστικό προϊόντος, όπως προκύπτει από τους κανόνες λέξεων-κλειδιών

Το ποσοστό 38,9% που καταλήγει στην κατηγορία uncategorised αποτελεί το μέτρο της ακρίβειας της μεθόδου και αναφέρεται ρητά. Οι κανόνες λέξεων-κλειδιών καλύπτουν επομένως περίπου τα τρία πέμπτα των εσόδων. Το υπόλοιπο δεν αποτελεί σφάλμα αλλά όριο της προσέγγισης, και η δήλωσή του επιτρέπει στον αναγνώστη να σταθμίσει ανάλογα τα συμπεράσματα της ενότητας.

Μια πηγή δεδομένων που παρέχει πραγματικές κατηγορίες θα πρέπει να τις διοχετεύει μέσω του προσαρμογέα της, οπότε το βήμα αυτό παρακάμπτεται.

5. Εξόρυξη συχνών υποσυνόλων

Η ανάλυση καλαθιού αγορών εντοπίζει προϊόντα που εμφανίζονται από κοινού στις ίδιες συναλλαγές συχνότερα από όσο θα δικαιολογούσε η τύχη. Αποτελεί άμεση απάντηση στο ερώτημα ποια προϊόντα παρουσιάζουν ιδιαίτερη συσχέτιση, όπως αυτή αποτυπώνεται στα διαθέσιμα δεδομένα.

5.1 Κατασκευή καλαθιών αγορών

Ως καλάθι ορίζεται το σύνολο των διακριτών προϊόντων μιας παραγγελίας. Δύο κανονικοποιήσεις εφαρμόζονται πριν την εξόρυξη.

Πρώτον, οι επαναλαμβανόμενες γραμμές του ίδιου προϊόντος εντός μιας παραγγελίας συμπτύσσονται. Η συνεμφάνιση είναι δυαδική ιδιότητα: η αγορά δύο τεμαχίων του ίδιου προϊόντος δεν προσθέτει πληροφορία συσχέτισης.

Δεύτερον, εξαιρούνται τα καλάθια με ένα μόνο προϊόν. Δεν μπορούν εξ ορισμού να συνεισφέρουν σε καμία συνεμφάνιση, ενώ στα δεδομένα λιανικής είναι πολυάριθμα. Η εξαίρεσή τους οξύνει τις τιμές υποστήριξης αντί να τις στρεβλώνει, καθώς ο παρονομαστής παύει να περιλαμβάνει συναλλαγές που δεν μπορούσαν να συνεισφέρουν.

5.2 Πειραματική διάταξη

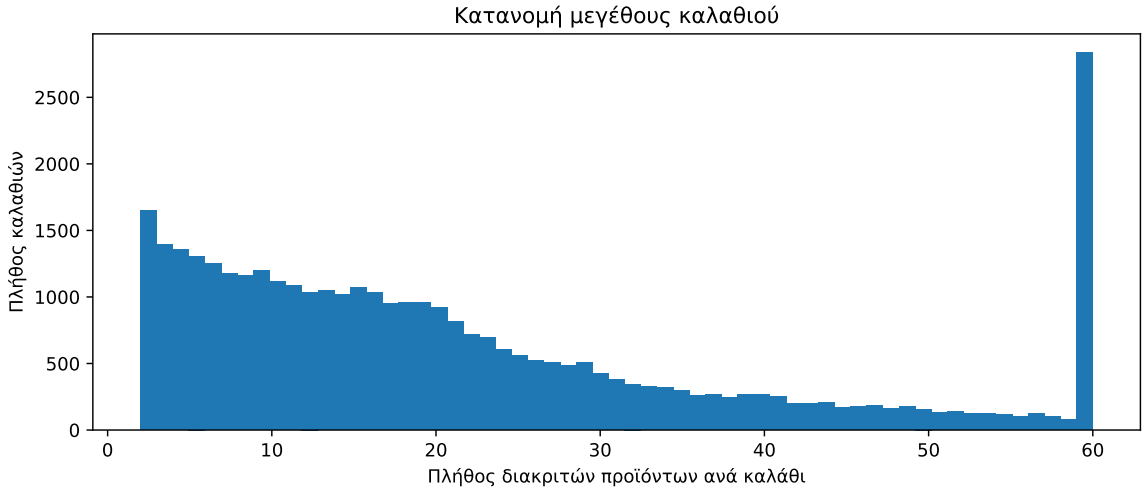
Χρησιμοποιούνται και οι δύο κλασικοί αλγόριθμοι, μέσω της βιβλιοθήκης mlxtend (Raschka, 2018). Ο Apriori (Agrawal & Srikant, 1994) παράγει υποψήφια σύνολα ανά επίπεδο, αξιοποιώντας την ιδιότητα ότι κάθε υποσύνολο ενός συχνού συνόλου είναι επίσης συχνό. Ο FP-Growth (Han κ.ά., 2000) κατασκευάζει δένδρο προθεμάτων και αποφεύγει εντελώς τη δημιουργία υποψηφίων.

Για το ίδιο κατώφλι υποστήριξης οι δύο αλγόριθμοι παράγουν ταυτόσημα συχνά υποσύνολα. Η επιλογή μεταξύ τους αφορά επομένως τον χρόνο εκτέλεσης και όχι το αποτέλεσμα, και η ισοδυναμία αυτή επαληθεύεται αυτόματα στη σουίτα ελέγχων.

Τα κατώφλια υποστήριξης και εμπιστοσύνης αποτελούν παραμέτρους της εκτέλεσης και αποθηκεύονται μαζί με τα αποτελέσματα. Μια τιμή υποστήριξης είναι άνευ νοήματος χωρίς το κατώφλι υπό το οποίο προέκυψε.

5.3 Αποτελέσματα

Από τις 39.516 παραγγελίες προκύπτουν 36.269 καλάθια με τουλάχιστον δύο διακριτά προϊόντα. Το διάμεσο καλάθι περιέχει 17 προϊόντα και το μέσο 26,9, ενώ το μεγαλύτερο φθάνει τα 1.108, μέγεθος που επιβεβαιώνει τον χονδρικό χαρακτήρα της επιχείρησης.



Εικόνα 5.1: Κατανομή του μεγέθους των καλαθιών, σε λογαριθμική κλίμακα

5.3.1 Σύγκριση των δύο αλγορίθμων

Για κατώφλι υποστήριξης 0,02 και εμπιστοσύνης 0,3, οι δύο αλγόριθμοι παρήγαγαν *ταυτόσημα* 385 συχνά υποσύνολα και 134 κανόνες, όπως αναμενόταν θεωρητικά. Η διαφορά εντοπίζεται αποκλειστικά στον χρόνο εκτέλεσης, όπου ο FP-Growth υπερέχει κατά συντελεστή 2,6.

Αλγόριθμος	Χρόνος (s)	Υποσύνολα	Κανόνες
Apriori	5,14	385	134
FP-Growth	1,96	385	134

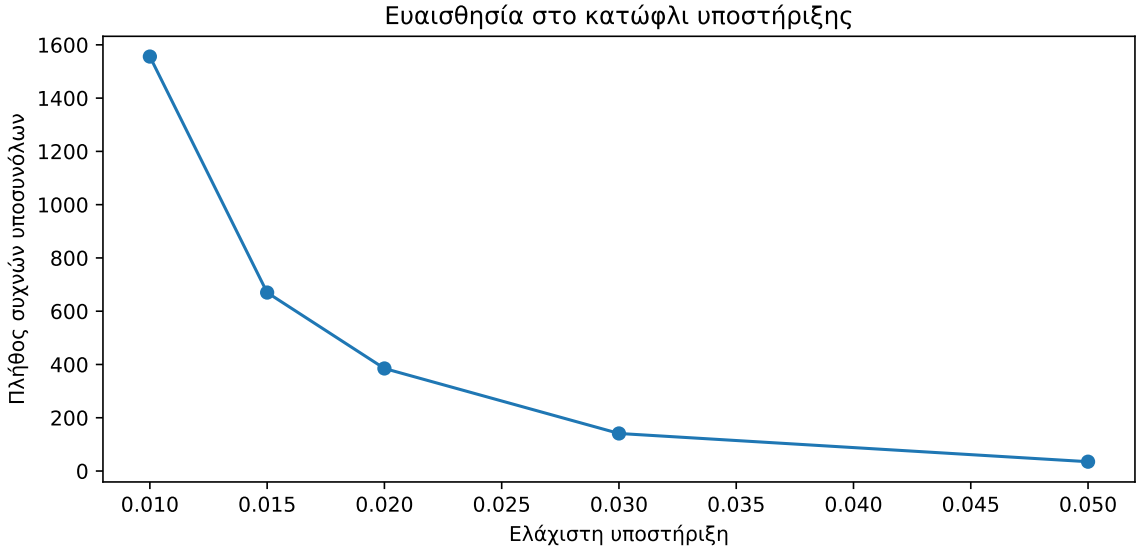
Πίνακας 5.1: Σύγκριση αλγορίθμων για υποστήριξη 0,02

5.3.2 Ευαισθησία στο κατώφλι υποστήριξης

Το κατώφλι δεν αποτελεί ουδέτερη παράμετρο: ορίζει την ίδια την έννοια του «συχνού». Η μείωσή του από 0,03 σε 0,01 δεκαπλασιάζει τα συχνά υποσύνολα.

Ελάχιστη υποστήριξη	Υποσύνολα	Κανόνες
0,01	1.556	1.185
0,02	385	134
0,03	141	17
0,05	35	0

Πίνακας 5.2: Επίδραση του κατωφλίου υποστήριξης



Εικόνα 5.2: Πλήθος συχνών υποσυνόλων και κανόνων ανά κατώφλι υποστήριξης

Στο κατώφλι 0,05 δεν επιβιώνει κανένα υποσύνολο με περισσότερα του ενός αντικείμενα, επομένως δεν παράγεται κανένας κανόνας. Το όριο αυτό είναι χαρακτηριστικό καταλόγου με 4.900 προϊόντα: κανένα ζεύγος δεν εμφανίζεται σε περισσότερο από το 5% των καλαθιών.

5.4 Αξιολόγηση κανόνων συσχέτισης

Κάθε κανόνας αξιολογείται με τρία μέτρα. Η υποστήριξη εκφράζει το ποσοστό των καλαθιών που περιέχουν και τα δύο σκέλη. Η εμπιστοσύνη εκφράζει την πιθανότητα του επακόλουθου δεδομένου του προηγούμενου. Η άρση (lift) είναι ο λόγος της εμπιστοσύνης προς την υποστήριξη του επακόλουθου.

5.4.1 Οι ισχυρότεροι κανόνες

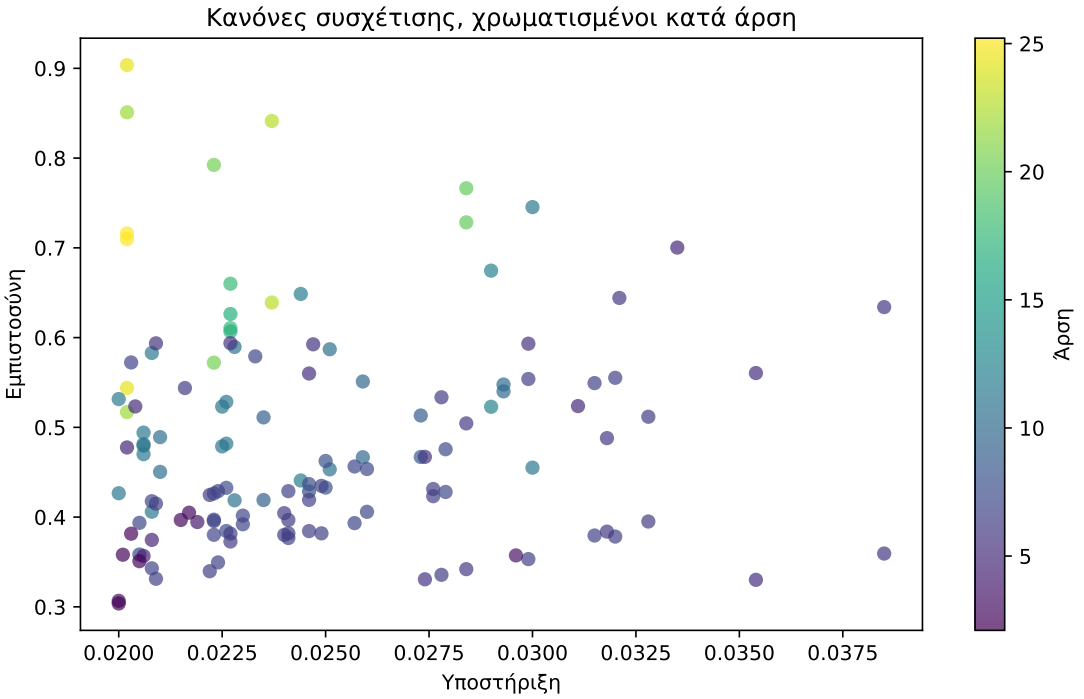
Οι κανόνες με την υψηλότερη άρση αφορούν αποκλειστικά τις χρωματικές παραλλαγές του ίδιου σερβιτσίου τσαγιού.

Προηγούμενο	Επακόλουθο	Υποστ.	Εμπιστ.	Άρση
22698	22697, 22699	0,020	0,716	25,21
22697, 22699	22698	0,020	0,710	25,21
22698, 22699	22697	0,020	0,904	24,38
22697	22698	0,024	0,639	22,70

Πίνακας 5.3: Κανόνες με την υψηλότερη άρση

Οι κωδικοί αντιστοιχούν στα προϊόντα GREEN REGENCY TEACUP AND SAUCER (22697), PINK REGENCY TEACUP AND SAUCER (22698) και ROSES REGENCY TEACUP AND SAUCER (22699).

Το εύρημα είναι άμεσα ερμηνεύσιμο και εμπορικά αξιοποιήσιμο: οι αγοραστές του συγκεκριμένου σερβιτσίου τείνουν να προμηθεύονται περισσότερες από μία χρωματικές παραλλαγές, με άρση περί το 25, δηλαδή εικοσιπενταπλάσια συνεμφάνιση από όσο θα προέβλεπε η ανεξαρτησία. Η πρακτική συνέπεια είναι ότι η προώθηση των παραλλαγών ως συλλογής, και όχι ως ανεξάρτητων κωδικών, έχει εμπειρική τεκμηρίωση.



Εικόνα 5.3: Οι 134 κανόνες ως προς υποστήριξη και εμπιστοσύνη, χρωματισμένοι κατά άρση. Οι ισχυρότερες συσχετίσεις δεν βρίσκονται στις υψηλότερες τιμές υποστήριξης

Η άρση είναι το κρίσιμο μέτρο για την ερμηνεία. Υποστήριξη και εμπιστοσύνη από μόνες τους αναδεικνύουν κανόνες των οποίων το επακόλουθο είναι απλώς δημοφιλές: ένα προϊόν που αγοράζεται σχεδόν πάντοτε θα εμφανίζεται με υψηλή εμπιστοσύνη ως επα-

κόλουθο οποιουδήποτε προηγούμενου, χωρίς να υπάρχει πραγματική συσχέτιση. Τιμή άρσης μεγαλύτερη της μονάδας δηλώνει ότι τα δύο σκέλη συνεμφανίζονται περισσότερο από όσο προβλέπει η ανεξαρτησία, και για τον λόγο αυτό το σύστημα φιλτράρει εξ ορισμού τους κανόνες με άρση κάτω της μονάδας.

6. Συσταδοποίηση

Η συσταδοποίηση εφαρμόζεται σε δύο επίπεδα, σύμφωνα με τη δομή που προτάθηκε από την επίβλεψη: μια πρώτη ομαδοποίηση ως προς τις παραμέτρους με τη μεγαλύτερη σημασία, δηλαδή την περιοχή και τον χρόνο, και εντός κάθε συστάδας μια δεύτερη ομαδοποίηση ως προς επιπρόσθετες παραμέτρους. Το αποτέλεσμα είναι δένδρο συστάδων, από κάθε κόμβο του οποίου μπορεί να εξαχθεί ανεξάρτητη πληροφορία.

6.1 Χαρακτηριστικά και κανονικοποίηση

Στο πρώτο επίπεδο κάθε περιοχή περιγράφεται από τα έσοδα, το πλήθος παραγγελιών, το πλήθος πελατών και το πλήθος των μηνών με δραστηριότητα. Το τελευταίο χαρακτηριστικό είναι αυτό που κάνει το σύνολο χωροχρονικό και όχι μόνο χωρικό: δύο περιοχές με ίδια έσοδα είναι στην ουσία εντελώς διαφορετικές αγορές, όταν η μία τα έβγαλε σταθερά μέσα στη χρονιά και η άλλη μαζεμένα σε έναν μήνα.

Στο δεύτερο επίπεδο κάθε πελάτης περιγράφεται από τα χαρακτηριστικά RFM που ορίστηκαν στην ενότητα 7.3.

Πριν από κάθε πέρασμα τα χαρακτηριστικά τυποποιούνται. Χωρίς τυποποίηση, ένα χαρακτηριστικό μετρημένο σε νομισματικές μονάδες θα κυριαρχούσε έναντι ενός μετρημένου σε πλήθη αποκλειστικά λόγω της κλίμακάς του, και ο αλγόριθμος θα ομαδοποιούσε ως προς τις μονάδες μέτρησης αντί ως προς τη συμπεριφορά. Η ιδιότητα αυτή επαληθεύεται με έλεγχο στον οποίο η πραγματική δομή βρίσκεται εξ ολοκλήρου στο χαρακτηριστικό μικρής κλίμακας.

6.2 Επιλογή του πλήθους συστάδων

Το πλήθος των συστάδων δεν καθορίζεται εκ των προτέρων. Για κάθε υποψήφια τιμή k υπολογίζεται ο δείκτης περιγράμματος (Rousseeuw, 1987) και επιλέγεται η τιμή με την υψηλότερη βαθμολογία. Η κατάτμηση προκύπτει επομένως από τα δεδομένα και όχι από παραδοχή, ενώ οι βαθμολογίες όλων των υποψηφίων τιμών καταγράφονται και παρατίθενται.

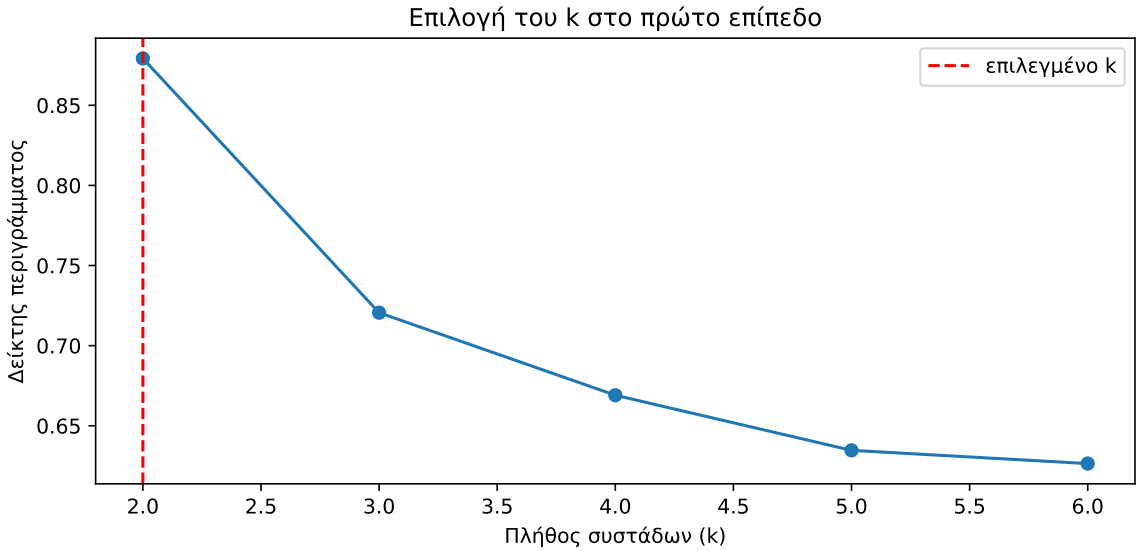
Όταν το πλήθος των εγγραφών δεν επαρκεί για ουσιαστική κατάτμηση, οι εγγραφές αναφέρονται ως μία συστάδα χωρίς δείκτη περιγράμματος. Η επιλογή αυτή είναι συνειδητή: προτιμάται η δήλωση της αδυναμίας από την επινόηση δομής που τα δεδομένα δεν στηρίζουν.

6.3 Πρώτο επίπεδο: περιοχή και χρόνος

Ο δείκτης περιγράμματος επέλεξε $k = 2$ με τιμή 0,879, σαφώς υψηλότερη από κάθε άλλη υποψήφια τιμή.

k	Δείκτης περιγράμματος
2	**0,8793**
3	0,7206
4	0,6691
5	0,6347
6	0,6264

Πίνακας 6.1: Επιλογή του πλήθους συστάδων στο πρώτο επίπεδο



Εικόνα 6.1: Δείκτης περιγράμματος ανά υποψήφιο πλήθος συστάδων στο πρώτο επίπεδο

Η κατάτμηση απομονώνει το Ηνωμένο Βασίλειο σε ιδιαίτερη συστάδα, έναντι των 42 αγορών εξαγωγής.

Συστάδα	Μέλη	Μ.ό. εσόδων	Μ.ό. παραγγελιών	Ενεργοί μήνες
[1]	42	67.298	79	12,8
[2]	1	16.679.730	36.184	25,0

Πίνακας 6.2: Συστάδες πρώτου επιπέδου

Το εύρημα δεν είναι τετριμμένο. Η συστάδα [2] δεν διαχωρίζεται μόνο λόγω μεγέθους αλλά και λόγω χρονικής συνέχειας: παρουσιάζει δραστηριότητα και στους 25 μήνες,

ενώ οι αγορές εξαγωγής κατά μέσο όρο σε 12,8. Η εγχώρια αγορά λειτουργεί συνεχώς, οι εξαγωγικές σποραδικά. Ακριβώς αυτή τη διάκριση αποτυπώνει το χαρακτηριστικό των ενεργών μηνών.

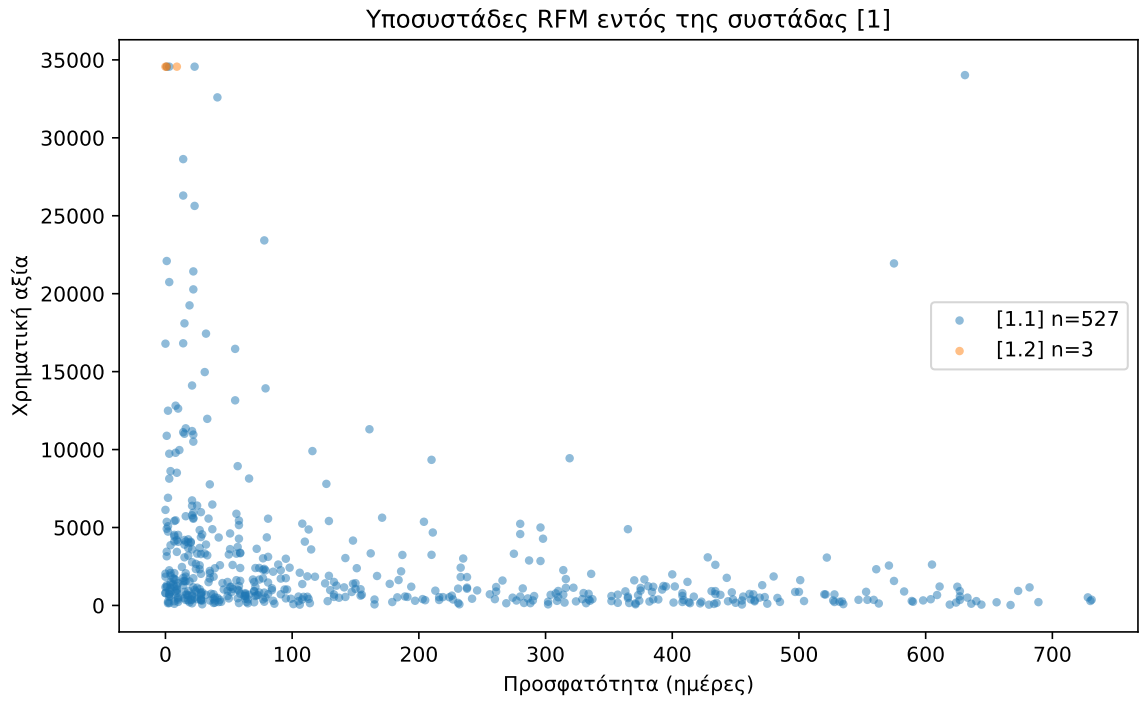
6.4 Δεύτερο επίπεδο: υποσυστάδες RFM

Εντός κάθε συστάδας πρώτου επιπέδου συγκεντρώνονται οι πελάτες όλων των περιοχών που την απαρτίζουν και ομαδοποιούνται εκ νέου. Η ομαδοποίηση γίνεται επί του συνόλου της συστάδας και όχι ανά περιοχή χωριστά, ώστε το δεύτερο επίπεδο να περιγράφει τη συμπεριφορά της αγοράς ως ενιαίας οντότητας.

Οι πελάτες χωρίς καταγεγραμμένη περιοχή δεν εντάσσονται στο δένδρο, καθώς δεν αντιστοιχούν σε κανέναν κλάδο του. Αναφέρονται μέσω της επίπεδης ανάλυσης RFM, αντί να αποδοθούν αυθαίρετα σε κάποια ομάδα.

Υποσυστάδα	Πελάτες	Προσφατότητα	Συχνότητα	Χρημ. αξία
[1.1]	527	178,1	4,88	3.161
[1.2]	3	3,3	220,67	365.705
[2.1]	5.309	202,4	5,72	2.138
[2.2]	25	19,9	120,36	114.404

Πίνακας 6.3: Υποσυστάδες RFM εντός κάθε συστάδας πρώτου επιπέδου



Εικόνα 6.2: Οι υποσυστάδες RFM εντός της συστάδας των αγορών εξαγωγής. Η τριμελής ομάδα υψηλής αξίας διαχωρίζεται καθαρά στην πάνω αριστερή περιοχή

Και στις δύο αγορές αναδύεται η ίδια δομή: μια πολυπληθής ομάδα περιστασιακών αγοραστών και μια πολύ μικρή ομάδα λογαριασμών με τάξεις μεγέθους υψηλότερη συχνότητα και αξία.

Στις αγορές εξαγωγής τρεις μόλις πελάτες παρουσιάζουν μέση συχνότητα 220 παραγγελιών και μέση αξία 365.705, έναντι 4,88 και 3.161 των υπολοίπων 527. Στο Ηνωμένο Βασίλειο 25 πελάτες ξεχωρίζουν αντίστοιχα από 5.309.

Η δομή αυτή επιβεβαιώνει ποσοτικά την παρατήρηση του κεφαλαίου 4 για την Ιρλανδία, και συνδέεται άμεσα με την ανάλυση συγκέντρωσης της ενότητας 7.4: πρόκειται για επιχείρηση με χονδρικό πυρήνα και λιανική ουρά, ανεξαρτήτως γεωγραφικής αγοράς.

6.5 Ερμηνεία των συστάδων

Κάθε κόμβος συνοδεύεται από τους μέσους όρους των χαρακτηριστικών του, οι οποίοι αποτελούν και τη βάση της ερμηνείας του. Οι συστάδες ταξινομούνται κατά φθίνον μέγεθος, ώστε η αρίθμηση να παραμένει σταθερή και συγκρίσιμη μεταξύ εκτελέσεων. Ο σπόρος τυχαιότητας είναι σταθερός, επομένως τα αποτελέσματα που παρατίθενται είναι πλήρως αναπαραγώγιμα.

7. Πρόβλεψη πωλήσεων και οικονομική ανάλυση

7.1 Πρόβλεψη χρονοσειρών πωλήσεων

Η χρονοσειρά που προβλέπεται είναι η καθαρή και όχι η ακαθάριστη αξία πωλήσεων. Οι επιστροφές αποτελούν χρήματα που επεστράφησαν, και μια πρόβλεψη επί της ακαθάριστης αξίας θα υπερεκτιμούσε συστηματικά το ποσό που η επιχείρηση μπορεί να αναμένει ότι θα διατηρήσει.

Εφαρμόζεται εκθετική εξομάλυνση κατά Holt-Winters (Holt, 1957; Winters, 1960), με προσθετική τάση και, όπου το ιστορικό επαρκεί, προσθετική εποχικότητα. Ο έλεγχος επάρκειας είναι ρητός: μια εποχική προσαρμογή απαιτεί τουλάχιστον δύο πλήρεις κύκλους, και όταν αυτοί δεν υπάρχουν το μοντέλο υποχωρεί σε προσαρμογή μόνο με τάση αντί να αποτύχει.

7.2 Αξιολόγηση της πρόβλεψης

Η αξιολόγηση γίνεται εκτός δείγματος. Ένα τμήμα στο τέλος της χρονοσειράς δεσμεύεται, το μοντέλο προσαρμόζεται αποκλειστικά στα προηγούμενα σημεία, και τα σφάλματα υπολογίζονται επί των δεσμευμένων παρατηρήσεων. Η τελική πρόβλεψη επαναπροσαρμόζεται στο σύνολο της σειράς, καθώς δεν υπάρχει λόγος απόρριψης των πλέον πρόσφατων παρατηρήσεων κατά την πρόβλεψη του μέλλοντος.

Αναφέρονται τρία μέτρα σφάλματος: το μέσο απόλυτο σφάλμα (MAE), η ρίζα του μέσου τετραγωνικού σφάλματος (RMSE), η οποία τιμωρεί βαρύτερα τις μεγάλες αποκλίσεις, και το μέσο απόλυτο ποσοστιαίο σφάλμα (MAPE).

Το MAPE δεν ορίζεται όταν κάποια πραγματική τιμή ισούται με μηδέν. Στην περίπτωση αυτή αναφέρεται ρητά ως μη ορισμένο. Η αντικατάστασή του με μικρή σταθερά ή η σιωπηρή παράλειψη των αντίστοιχων σημείων θα κολάκευε τεχνηέντως το μοντέλο.

7.2.1 Αποτελέσματα και το ζήτημα της τελευταίας περιόδου

Η αρχική εκτέλεση επί των 25 διαθέσιμων μηνών έδωσε *αρνητικό* δείκτη δεξιότητας, ίσο με $-0{,}21$: το μοντέλο εκθετικής εξομάλυνσης απέδωσε χειρότερα από την αφελή επανάληψη της τελευταίας τιμής.

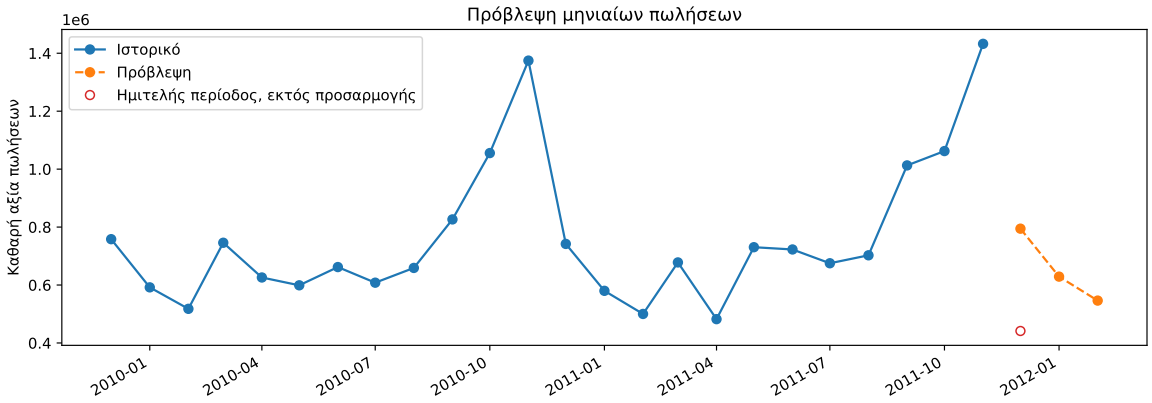
Η διερεύνηση ανέδειξε τη αιτία. Το σύνολο δεδομένων τερματίζει στις 9 Δεκεμβρίου 2011, επομένως ο τελευταίος μήνας περιέχει εννέα μόνο ημέρες. Η καταγεγραμμένη τιμή

του, 441.367, δεν αποτελεί πτώση αλλά αποκοπή, και βρίσκεται εντός του διαστήματος ελέγχου.

Ο αποκλεισμός της ημιτελούς περιόδου αντιστρέφει το συμπέρασμα.

Μέθοδος	MAE	RMSE	MAPE (%)	Δείκτης δεξιότητας
Αφελής	466.648	502.808	38,48	0,0000
Εκθετική εξομάλυνση	400.355	439.920	32,74	+0,1421

Πίνακας 7.1: Ακρίβεια πρόβλεψης μετά τον αποκλεισμό της ημιτελούς περιόδου



Εικόνα 7.1: Καθαρή αξία πωλήσεων ανά μήνα και πρόβλεψη τριών μηνών. Ο ημιτελής Δεκέμβριος του 2011 σημειώνεται χωριστά και εξαιρείται από την προσαρμογή

Το εύρημα είναι μεθοδολογικά σημαντικότερο από τους ίδιους τους αριθμούς: η μη αναγνώριση μιας αποκομμένης περιόδου δεν υποβαθμίζει απλώς την ακρίβεια, αλλά αντιστρέφει το πρόσημο του συμπεράσματος για το αν το μοντέλο αξίζει καθόλου.

Επισημαίνεται επίσης ότι η εποχική προσαρμογή δεν ενεργοποιήθηκε. Με 24 μήνες ιστορικού, το τμήμα εκπαίδευσης του ελέγχου εκτός δείγματος περιορίζεται σε 21 μήνες, κάτω από τους δύο πλήρεις ετήσιους κύκλους που απαιτεί η εκτίμηση εποχικότητας, οπότε το μοντέλο υποχώρησε ορθώς σε προσαρμογή μόνο με τάση. Το υπολειπόμενο MAPE της τάξης του 33% οφείλεται σε μεγάλο βαθμό ακριβώς σε αυτή την ανεπάρκεια: η σειρά παρουσιάζει έντονη ετήσια εποχικότητα, με κορύφωση τον Νοέμβριο και των δύο ετών, την οποία δύο μόλις κύκλοι δεν επαρκούν να μοντελοποιήσουν αξιόπιστα.

7.2.2 Σύγκριση με αφελή βασική γραμμή

Κάθε πρόβλεψη συνοδεύεται από αφελή βασική γραμμή, η οποία απλώς επαναλαμβάνει την τελευταία παρατηρούμενη τιμή. Η απόφαση αυτή είναι μεθοδολογικά κρίσιμη: ένα μοντέλο που δεν υπερβαίνει την πρόταση «το αύριο μοιάζει με το σήμερα» δεν έχει

αποδείξει τίποτε, και ένα MAPE που παρατίθεται χωρίς τέτοια σύγκριση αποτελεί μη διαψεύσιμο αριθμό.

Η βελτίωση εκφράζεται μέσω του δείκτη δεξιότητας (skill score), ως το κλασματικό κέρδος στο μέσο απόλυτο σφάλμα έναντι της βασικής γραμμής. Ο δείκτης μπορεί να λάβει αρνητική τιμή, και στην περίπτωση αυτή αναφέρεται ως έχει.

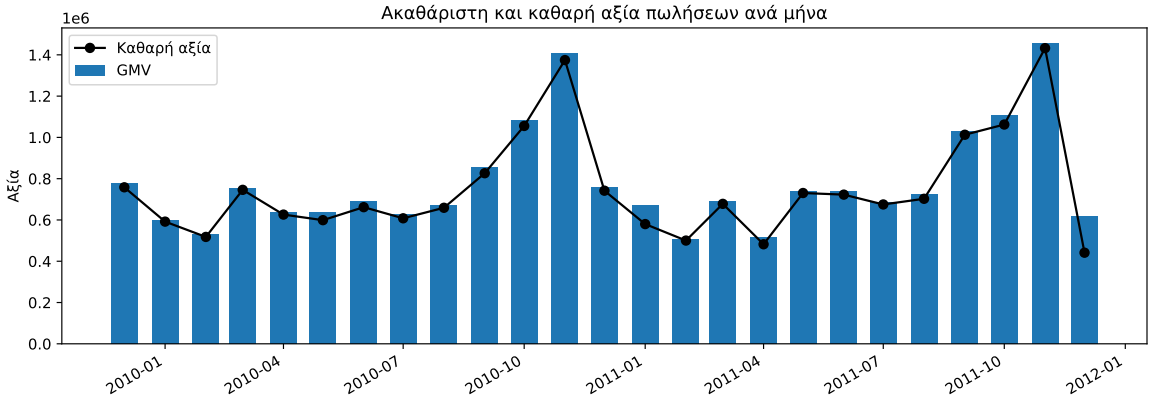
Η πιθανότητα αρνητικού δείκτη δεν αποτελεί ιδιαιτερότητα των παρόντων δεδομένων. Στον διαγωνισμό M5, όπου προβλέφθηκαν 42.840 χρονοσειρές λιανικών πωλήσεων, οι καθαρά στατιστικές μέθοδοι υπολείφθηκαν συστηματικά των μεθόδων μηχανικής μάθησης, με τις νικήτριες συμμετοχές να τις υπερβαίνουν κατά περισσότερο από 20% (Makridakis κ.ά., 2022). Η εκθετική εξομάλυνση επιλέχθηκε εδώ γιατί είναι διαφανής και δεν θέλει πολύ ιστορικό, όχι επειδή είναι η ακριβέστερη διαθέσιμη μέθοδος, και ο δείκτης δεξιότητας είναι ακριβώς το μέγεθος που κάνει αυτό το όριο ορατό αντί να το κρύβει.

7.3 Μετρήσιμοι οικονομικοί δείκτες

Οι δείκτες της ενότητας αυτής υπολογίζονται απευθείας από τα δεδομένα συναλλαγών. Δεν μπαίνει καμία παραδοχή εδώ, και η διαφορά με την ενότητα 7.5 που ακολουθεί είναι ουσιαστική.

7.3.1 Ακαθάριστη αξία πωλήσεων

Η ακαθάριστη αξία πωλήσεων (Gross Merchandise Value, GMV) αναφέρεται πριν από τις επιστροφές, σύμφωνα με τον καθιερωμένο ορισμό. Η αξία των επιστροφών και η καθαρή αξία παρατίθενται δίπλα της, ώστε κανένα από τα δύο μεγέθη να μην αποκρύπτεται. Ο χειρισμός αυτός είναι συνεπής με τη σχεδίαση του σχήματος δεδομένων, όπου οι επιστροφές αποτελούν αυτοτελείς εγγραφές και δεν αφαιρούνται σιωπηρά από τα έσοδα.



Εικόνα 7.2: Ακαθάριστη αξία πωλήσεων, αξία επιστροφών και καθαρή αξία ανά μήνα

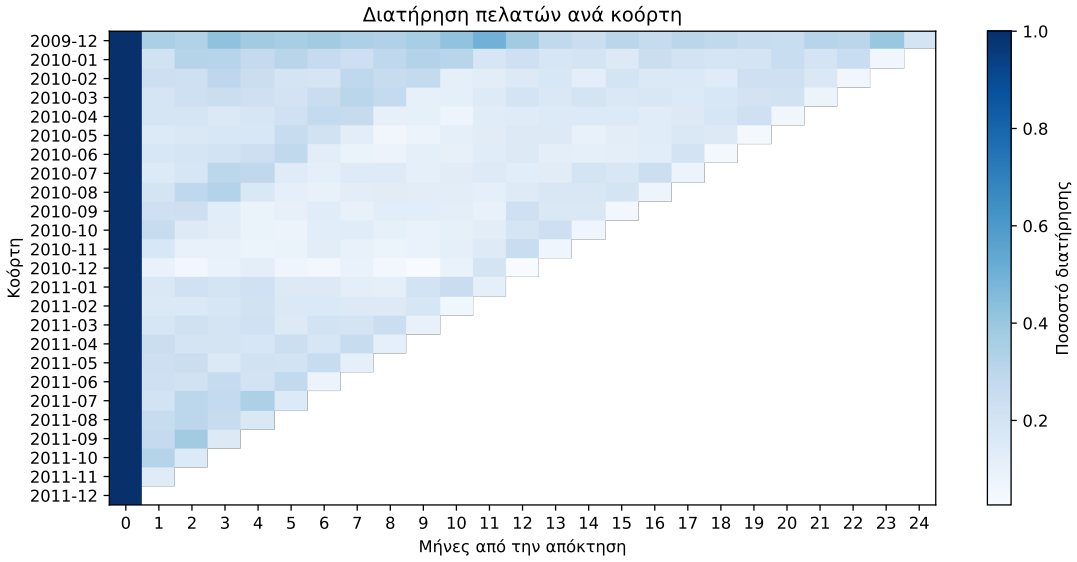
7.3.2 Ποσοστό επαναληπτικών αγορών

Στα δεδομένα, το ποσοστό επαναληπτικών αγορών ανέρχεται σε 72,4%, με 4.234 επαναλαμβανόμενους έναντι 1.618 εφάπαξ πελατών, μέσο όρο 6,25 παραγγελιών ανά πελάτη και μέση αξία παραγγελίας 493,63. Οι τιμές αυτές είναι χαρακτηριστικές χονδρικής και όχι λιανικής: στο λιανικό ηλεκτρονικό εμπόριο τα τυπικά ποσοστά επαναληπτικότητας κινούνται πολύ χαμηλότερα.

Ως επαναλαμβανόμενος θεωρείται ο πελάτης με περισσότερες από μία παραγγελίες. Στον υπολογισμό συμμετέχουν μόνο οι αναγνωρισμένοι πελάτες: οι ανώνυμες πωλήσεις δεν μπορούν να αποδοθούν σε πρόσωπο, και η συμπερίληψή τους θα υποεκτιμούσε συστηματικά την επαναληπτικότητα.

7.3.3 Διατήρηση πελατών ανά κοόρτη

Οι πελάτες ομαδοποιούνται με βάση τον μήνα της πρώτης τους αγοράς και παρακολουθούνται στους επόμενους μήνες. Ο δείκτης περιόδου μετρά τους συμπληρωμένους μήνες από την απόκτηση, οπότε η τιμή μηδέν αντιστοιχεί στον ίδιο τον μήνα της κοόρτης. Το πλέγμα που προκύπτει είναι εξ ορισμού τριγωνικό, καθώς οι νεότερες κοόρτες διαθέτουν λιγότερους μήνες παρακολούθησης.



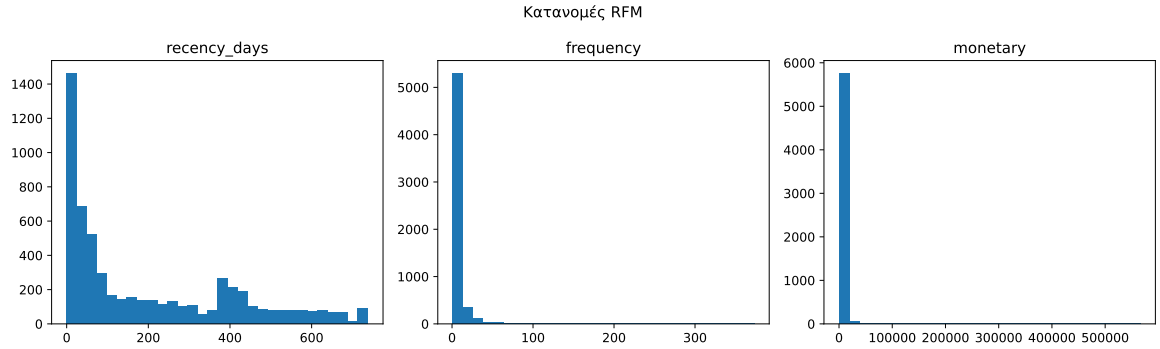
Εικόνα 7.3: Διατήρηση πελατών ανά κοόρτη πρώτης αγοράς. Το πλέγμα είναι εξ ορισμού τριγωνικό

7.3.4 Ανάλυση RFM

Για κάθε πελάτη υπολογίζονται η προσφατότητα (recency), η συχνότητα (frequency) και η χρηματική αξία (monetary). Η προσφατότητα μετράται σε συμπληρωμένες ημέρες από

την τελευταία αγορά, ως προς ημερομηνία αναφοράς που εξ ορισμού είναι η τελευταία παραγγελία του συνόλου δεδομένων· η επιλογή αυτή διατηρεί τα αποτελέσματα αναπαραγώγιμα για ένα ιστορικό σύνολο δεδομένων, αντί να μεταβάλλονται με την τρέχουσα ημερομηνία.

Η χρηματική αξία αποτελεί την παρατηρούμενη αξία του πελάτη μέχρι σήμερα και όχι πρόβλεψη αξίας διάρκειας ζωής. Δεν εμπλέκεται κανένα μοντέλο σε αυτό το στάδιο. Τα ίδια χαρακτηριστικά τροφοδοτούν τη συσταδοποίηση δεύτερου επιπέδου του κεφαλαίου 6, ακολουθώντας την προσέγγιση των Chen κ.ά. (2012).



Εικόνα 7.4: Κατανομές των τριών μεγεθών RFM στο σύνολο των πελατών

7.4 Λογιστική ανάπτυξης και ποσοτική προσαρμογή προϊόντος-αγοράς

Οι δείκτες της ενότητας αυτής απαντούν στο ερώτημα αν η ανάπτυξη μιας επιχείρησης είναι υγιής, και το κάνουν αποκλειστικά από τα δεδομένα συναλλαγών. Σε αντίθεση με την ανάλυση κερδοφορίας που ακολουθεί, εδώ δεν εισάγεται καμία παραδοχή.

Η προσέγγιση βασίζεται στο ποσοτικό πλαίσιο προσαρμογής προϊόντος-αγοράς (product-market fit) που διατύπωσε η Tribe Capital,[1] προσαρμοσμένο στο λιανικό εμπόριο.

7.4.1 Αποσύνθεση των εσόδων σε ροές

Η μεταβολή των εσόδων αναλύεται σε έξι ροές. Ανά περίοδο, τα έσοδα κάθε πελάτη κατατάσσονται σε μία ακριβώς από αυτές:

- **Νέα**: πρώτα έσοδα που παράγει ποτέ ο πελάτης.
- **Αναβιωμένα**: πελάτης ενεργός ξανά μετά από αδρανή περίοδο.
- **Διατηρημένα**: το τμήμα των εσόδων της προηγούμενης περιόδου που επαναλήφθηκε.

[1] Tribe Capital, A Quantitative Approach to Product Market Fit. Πρόκειται για πλαίσιο της επενδυτικής πρακτικής και όχι για αξιολογημένη από ομοτίμους έρευνα.

- **Επέκταση**: η αύξηση πάνω από τα διατηρημένα έσοδα.
- **Συρρίκνωση**: η μείωση έναντι της προηγούμενης περιόδου, με τον πελάτη να παραμένει ενεργός.
- **Απώλεια**: τα έσοδα της προηγούμενης περιόδου από πελάτη που πλέον είναι αδρανής.

Οι ροές αυτές ικανοποιούν δύο λογιστικές ταυτότητες:

$$\text{έσοδα}(t) = \text{διατηρημένα} + \text{επέκταση} + \text{νέα} + \text{αναβιωμένα} \tag{7.1}$$

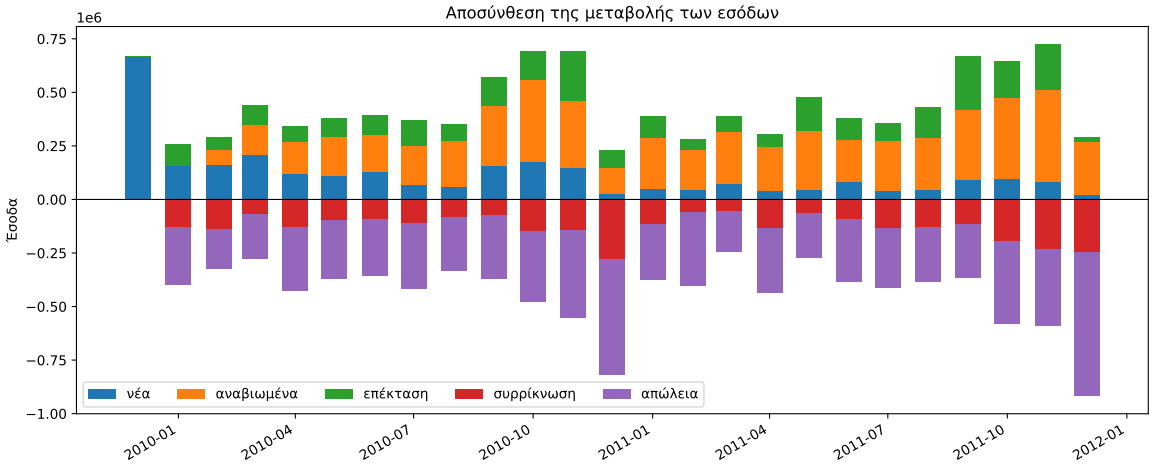
$$\text{έσοδα}(t-1) = \text{διατηρημένα} + \text{συρρίκνωση} + \text{απώλεια} \tag{7.2}$$

Οι ταυτότητες δεν αποτελούν σχόλιο αλλά ελεγχόμενη ιδιότητα: επαληθεύονται αυτόματα στη σουίτα ελέγχων, τόσο σε συνθετικά δεδομένα όσο και επί των πραγματικών εισαγόμενων πωλήσεων. Μια αποσύνθεση που δεν ισοσκελίζει είναι εξ ορισμού εσφαλμένη.

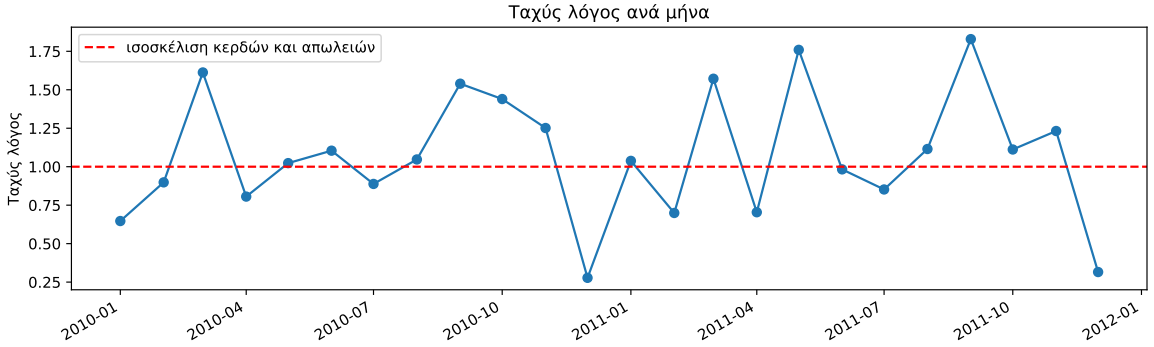
7.4.2 Παράγωγοι δείκτες

Από τις ροές προκύπτουν τρεις δείκτες:

- **Ταχύς λόγος** (quick ratio): το άθροισμα νέων, αναβιωμένων και επέκτασης προς το άθροισμα απώλειας και συρρίκνωσης. Τιμή κάτω της μονάδας σημαίνει ότι τα συνολικά έσοδα συρρικνώνονται.
- **Καθαρή απώλεια** (net churn): η καθαρή απώλεια ως ποσοστό των εσόδων της προηγούμενης περιόδου. Αρνητική τιμή σημαίνει ότι η επέκταση και οι αναβιώσεις υπερκαλύπτουν τις απώλειες, δηλαδή ότι η επιχείρηση μεγεθύνεται χωρίς νέους πελάτες.
- **Ακαθάριστη διατήρηση**: τα διατηρημένα έσοδα προς τα έσοδα της προηγούμενης περιόδου.



Εικόνα 7.5: Αποσύνθεση της μεταβολής των εσόδων στις έξι ροές. Οι θετικές ροές σχεδιάζονται πάνω από τον άξονα και οι αρνητικές κάτω



Εικόνα 7.6: Ταχύς λόγος ανά μήνα. Τιμή κάτω της μονάδας σημαίνει συρρίκνωση των συνολικών εσόδων

7.4.3 Συγκέντρωση εσόδων

Ο πίνακας που ακολουθεί αφορά τους 5.852 πελάτες με αναγνωρισμένη ταυτότητα και τουλάχιστον μία γραμμή εσόδων, όχι το σύνολο των 5.875 πελατών του Πίνακα 3.1: οι ανώνυμες πωλήσεις δεν μπορούν να αποδοθούν σε πρόσωπο και εξαιρούνται εξ ορισμού από κάθε ανάλυση σε επίπεδο πελάτη, όπως δηλώνεται και στους περιορισμούς του κεφαλαίου 8.

Μέγεθος	Τιμή
Πελάτες	5.852
Συντελεστής Gini	0,740
Μερίδιο κορυφαίου 10%	63,7%
Μερίδιο κορυφαίου 20%	77,1%
Μερίδιο κορυφαίου 50%	93,5%
Μερίδιο μεγαλύτερου πελάτη	3,3%

Πίνακας 7.2: Συγκέντρωση εσόδων στους πελάτες

Η κατανομή είναι έντονα ασύμμετρη, με το κορυφαίο πεμπτημόριο να παράγει το 77% των εσόδων. Κρίσιμη ωστόσο είναι η τελευταία γραμμή: ο μεγαλύτερος μεμονωμένος πελάτης αντιστοιχεί μόλις στο 3,3%.

Η διάκριση έχει σημασία. Υψηλή συγκέντρωση με ταυτόχρονη απουσία εξάρτησης από μεμονωμένο πελάτη περιγράφει υγιή χονδρική δομή, όχι εύθραυστη. Ένας δείκτης Gini (Gini, 1912) εξεταζόμενος χωρίς το μερίδιο του μεγαλύτερου πελάτη θα οδηγούσε σε λανθασμένο συμπέρασμα κινδύνου.

Το δεύτερο σκέλος του πλαισίου εξετάζει την κατανομή των εσόδων στους πελάτες. Υπολογίζονται τα μερίδια της κορυφαίας δεκάτης, του κορυφαίου πεμπτημορίου και του κορυφαίου ημίσεος, το μερίδιο του μεγαλύτερου πελάτη και ο συντελεστής Gini.

Το μέγεθος αυτό διακρίνει μια κλιμακώσιμη επιχείρηση από μια που στηρίζεται σε λίγους μεγάλους λογαριασμούς. Ένα κατάστημα του οποίου οι δύο κορυφαίοι πελάτες παράγουν το μεγαλύτερο μέρος των εσόδων συμπεριφέρεται ως χονδρέμπορος με βασικούς πελάτες, ανεξαρτήτως του πώς αυτοπροσδιορίζεται.

7.4.4 Γενικότητα και απουσία κατωφλίων

Το πλαίσιο είναι σκοπίμως ανεξάρτητο από το επιχειρηματικό μοντέλο. Ένα κατάστημα συνδρομών, ένα κατάστημα δώρων μίας αγοράς και ένας χονδρέμπορος παράγουν όλα τις ίδιες έξι ροές, γεγονός που επιτρέπει τη σύγκριση εκεί όπου ένα σταθερό σημείο αναφοράς θα ήταν παραπλανητικό.

Γι' αυτό δεν ορίζονται απόλυτα κατώφλια. Ο ταχύς λόγος χωρίζει αριθμητικά την ανάπτυξη από τη συρρίκνωση στη μονάδα, αλλά το ποια τιμή είναι *υγιής* εξαρτάται από το μοντέλο. Οι δείκτες αναφέρονται και η ερμηνεία τους αφήνεται στον αναγνώστη, όπως κάνουν και όσοι πρότειναν το πλαίσιο.

7.5 Ανάλυση κερδοφορίας βάσει σεναρίων

Τα ερωτήματα «είναι η επιχείρηση κερδοφόρα» και «πότε θα γίνει κερδοφόρα» *δεν* απαντώνται από τα διαθέσιμα δεδομένα. Το σύνολο δεδομένων καταγράφει τι πωλήθηκε και σε ποια τιμή, δεν καταγράφει όμως ούτε κόστος πωληθέντων ούτε δαπάνες marketing. Οποιοδήποτε μέγεθος κερδοφορίας παρουσιαζόταν ως μετρημένο θα αποτελούσε επινόηση με το ένδυμα ευρήματος.

Αυτό που μπορεί να γίνει με ακαδημαϊκή εντιμότητα είναι ανάλυση ευαισθησίας: δήλωση ρητών παραδοχών, μεταβολή τους, και καταγραφή του τι προκύπτει *εφόσον* αυτές ισχύουν.

7.5.1 Δηλωμένες παραδοχές

Οι παραδοχές είναι δύο, το μεικτό περιθώριο κέρδους και το κόστος απόκτησης πελάτη, και προαιρετικά ένα σταθερό λειτουργικό κόστος ανά περίοδο. Δεν προκύπτουν από τα δεδομένα και δεν υπονοούνται πουθενά: παρέχονται από τον χρήστη και επιστρέφονται μαζί με κάθε αποτέλεσμα, ώστε παραδοχή και συμπέρασμα να μην μπορούν να αποσυνδεθούν.

Κάθε απόκριση του συστήματος φέρει επιπλέον ρητή δήλωση ότι πρόκειται για σενάριο και όχι για μέτρηση. Η δήλωση αυτή ταξιδεύει μαζί με τα δεδομένα σε όλα τα επίπεδα, από τον κώδικα έως το API, ακριβώς για να μην μπορεί να αφαιρεθεί εκ παραδρομής.

7.5.2 Σημεία αναφοράς της αγοράς

Ως πλαίσιο σύγκρισης χρησιμοποιούνται δημοσιευμένες εκτιμήσεις της αγοράς: το μεικτό περιθώριο κυμαίνεται περίπου από 15-30% στα ηλεκτρονικά έως 65-85% στα καλλυντικά και τα συμπληρώματα, ο λόγος αξίας διάρκειας ζωής προς κόστος απόκτησης θεωρείται υγιής περί το 3:1, και η περίοδος απόσβεσης του κόστους απόκτησης τυπικά κινείται μεταξύ 6 και 12 μηνών.[2]

7.5.3 Αξία διάρκειας ζωής και απόσβεση

Η αξία διάρκειας ζωής υπολογίζεται επί του μεικτού κέρδους και όχι επί των εσόδων. Η σύγκριση εσόδων με το κόστος απόκτησης θα υπερεκτιμούσε τον λόγο ακριβώς κατά το κόστος πωληθέντων, και αποτελεί τον συνηθέστερο τρόπο με τον οποίο ο δείκτης αυτός εμφανίζεται τεχνηέντως ευνοϊκός.

[2] Εκτιμήσεις κλάδου από επαγγελματικές πηγές, οι οποίες δεν αποτελούν αξιολογημένη από ομοτίμους έρευνα. Παρατίθενται ως πλαίσιο για την οριοθέτηση εύλογων τιμών των παραδοχών και όχι ως μεγέθη της συγκεκριμένης επιχείρησης.

Η περίοδος απόσβεσης προϋποθέτει ρυθμό κέρδους, επομένως απαιτεί και το μέσο πλήθος περιόδων δραστηριότητας του πελάτη. Όταν αυτό δεν είναι διαθέσιμο, η περίοδος απόσβεσης αναφέρεται ως μη ορισμένη αντί να εκτιμηθεί αυθαίρετα.

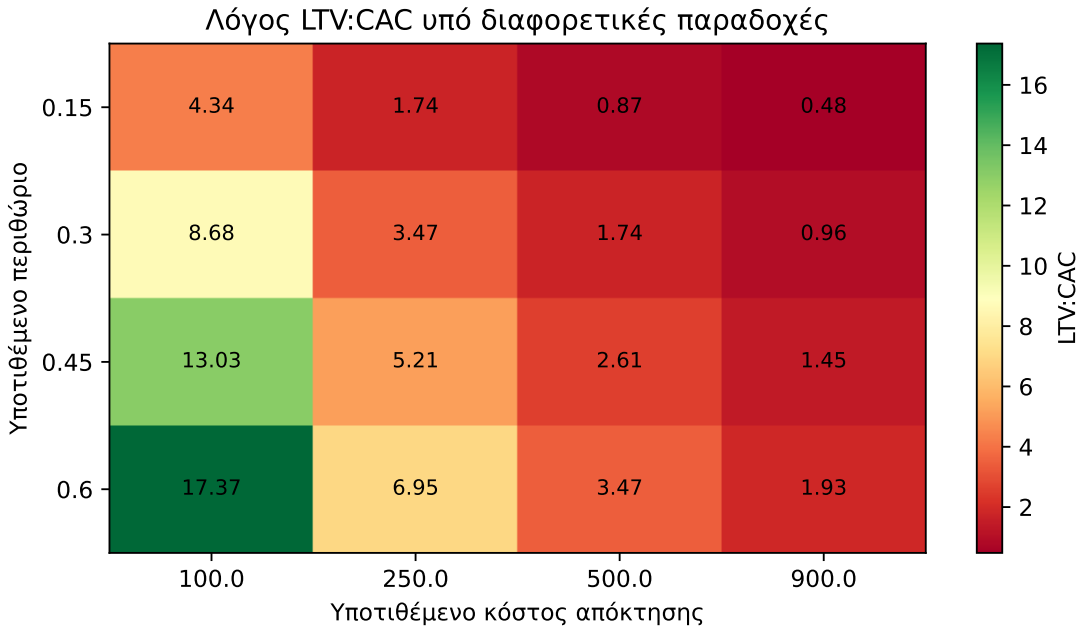
7.5.4 Πλέγμα ευαισθησίας

Ένα μεμονωμένο σενάριο προσκαλεί την ανάγνωσή του ως πρόβλεψης. Για τον λόγο αυτό τα αποτελέσματα παρουσιάζονται ως πλέγμα πάνω σε εύρος παραδοχών.

Η μέση παρατηρούμενη αξία ανά πελάτη ανέρχεται σε 2.895. Το πλέγμα εκτείνεται σε περιθώρια 15–60% και κόστη απόκτησης 100–900, εύρος επιλεγμένο ώστε να περιλαμβάνει το όριο απόφασης· ένα στενότερο εύρος θα παρήγαγε ομοιόμορφα θετικό αποτέλεσμα και δεν θα τεκμηρίωνε τίποτε.

Περιθώριο	CAC	LTV	LTV:CAC	Πληροί 3:1
0,15	100	434	4,34	ναι
0,15	250	434	1,74	όχι
0,15	900	434	0,48	όχι
0,30	250	868	3,47	ναι
0,30	500	868	1,74	όχι
0,45	250	1.303	5,21	ναι
0,45	500	1.303	2,61	όχι
0,60	500	1.737	3,47	ναι
0,60	900	1.737	1,93	όχι

Πίνακας 7.3: Ανάλυση ευαισθησίας των μοναδιαίων οικονομικών



Εικόνα 7.7: Λόγος αξίας διάρκειας ζωής προς κόστος απόκτησης, για κάθε συνδυασμό παραδοχών. Το πλήρες πλέγμα παρατίθεται στο παράρτημα Β

Από τα δεκαέξι κελιά του πλήρους πλέγματος, οκτώ πληρούν το σημείο αναφοράς 3:1 και οκτώ όχι.

Το πλέγμα δείχνει καθαρά πόσο εξαρτάται το συμπέρασμα από τις παραδοχές: τα ίδια ακριβώς δεδομένα βγάζουν αντίθετα συμπεράσματα ως προς το σημείο αναφοράς 3:1, ανάλογα και μόνο με το περιθώριο κέρδους που θα υποθέσουμε. Η ιδιότητα αυτή επαληθεύεται αυτόματα στη σουίτα ελέγχων και αποτελεί το κεντρικό συμπέρασμα της ενότητας.

7.5.5 Προβολή στον χρόνο

Η προβολή κερδοφορίας εκτείνεται στις καταγεγραμμένες και στις προβλεπόμενες περιόδους ως ενιαία σειρά, με ρητή σήμανση του ορίου μεταξύ τους. Μια προβολή που στηρίζεται σε προβλεπόμενα έσοδα είναι ασθενέστερη από μία που στηρίζεται σε καταγεγραμμένα, και ο αναγνώστης δικαιούται να γνωρίζει πού βρίσκεται αυτό το όριο. Για τον ίδιο λόγο αναφέρεται και ο δείκτης δεξιότητας της υποκείμενης πρόβλεψης της ενότητας 7.1.

8. Συζήτηση και συμπεράσματα

8.1 Σύνοψη των ευρημάτων

Η εργασία υλοποίησε σύστημα το οποίο απαντά στα επτά ερωτήματα που τέθηκαν από την πλευρά της επιχείρησης, και εφαρμόζει επιπλέον τρεις οικογένειες τεχνικών εξόρυξης δεδομένων και μηχανικής μάθησης.

Στο περιγραφικό σκέλος, οι επτά αναλύσεις υλοποιήθηκαν ως συναθροίσεις εντός της βάσης δεδομένων, με δύο ιδιότητες που επαληθεύονται αυτόματα: τόσο η κατηγοριοποίηση ανά εύρος τιμής όσο και εκείνη ανά χαρακτηριστικό προϊόντος διαμερίζουν πλήρως τα έσοδα, χωρίς διπλομέτρηση ή απώλεια.

Στην εξόρυξη συχνών υποσυνόλων επαληθεύθηκε ότι οι δύο κλασικοί αλγόριθμοι παράγουν ταυτόσημα αποτελέσματα για το ίδιο κατώφλι, επιβεβαιώνοντας πειραματικά ότι η επιλογή μεταξύ τους αφορά τον χρόνο εκτέλεσης.

Στη συσταδοποίηση, η εμφωλευμένη δομή που προτάθηκε από την επίβλεψη υλοποιήθηκε με επιλογή του πλήθους συστάδων μέσω του δείκτη περιγράμματος σε κάθε επίπεδο, αντί ορισμού του εκ των προτέρων.

Στην πρόβλεψη, κάθε αποτέλεσμα συνοδεύεται από αφελή βασική γραμμή και δείκτη δεξιότητας. Η επιλογή αυτή αποτρέπει την παρουσίαση ενός μοντέλου ως επιτυχούς όταν δεν υπερβαίνει την τετριμμένη πρόβλεψη.

Τέλος, η λογιστική ανάπτυξης προσέφερε το ισχυρότερο μετρήσιμο τεκμήριο για την υγεία μιας επιχείρησης, καθώς αποσυνθέτει τη μεταβολή των εσόδων χωρίς καμία παραδοχή.

8.2 Πρακτική αξιοποίηση από την επιχείρηση

Τα αποτελέσματα διατίθενται με τρεις τρόπους: ως σημεία πρόσβασης API, ως πίνακες ελέγχου Metabase, και ως σημειωματάρια για διερευνητική ανάλυση.

Ως προς τις αποφάσεις marketing, οι κανόνες συσχέτισης με άρση μεγαλύτερη της μονάδας υποδεικνύουν συνδυασμούς προϊόντων που αξίζει να προωθηθούν από κοινού. Οι συστάδες πελατών επιτρέπουν διαφοροποιημένη επικοινωνία ανά ομάδα συμπεριφοράς αντί για ενιαία. Η ανάλυση συγκέντρωσης εσόδων αποκαλύπτει εξάρτηση από λίγους μεγάλους πελάτες, κίνδυνο που κανένας ρυθμός ανάπτυξης δεν αναδεικνύει από μόνος του.

Ως προς τις αποφάσεις πωλήσεων, η χρονική κατανομή και η πρόβλεψη υποστηρίζουν τον προγραμματισμό αποθέματος, ενώ η ανάλυση επιστροφών εντοπίζει προϊόντα των οποίων το πραγματικό περιθώριο υπονομεύεται από το ποσοστό επιστροφών.

8.3 Περιορισμοί

Οι περιορισμοί δηλώνονται ανοιχτά, γιατί αν τους αποσιωπούσαμε τα συμπεράσματα θα ήταν παραπλανητικά.

8.3.1 Απουσία στοιχείων κόστους

Το σύνολο δεδομένων δεν περιέχει κόστος πωληθέντων ούτε δαπάνες marketing. Επομένως τα ερωτήματα κερδοφορίας *δεν απαντώνται* από την εργασία ως μετρήσεις. Απαντώνται αποκλειστικά ως ανάλυση ευαισθησίας πάνω σε δηλωμένες παραδοχές, όπως αναπτύχθηκε στην ενότητα 7.5.

Το κεντρικό συμπέρασμα της ενότητας αυτής δεν είναι κάποια τιμή κερδοφορίας αλλά η ίδια η ευαισθησία: τα ίδια ακριβώς δεδομένα οδηγούν σε αντίθετα συμπεράσματα ανάλογα με το υποτιθέμενο περιθώριο κέρδους.

8.3.2 Απουσία δομημένης κατηγοριοποίησης

Τα χαρακτηριστικά προϊόντων προκύπτουν με κανόνες λέξεων-κλειδιών επί ελεύθερου κειμένου. Η ακρίβεια της μεθόδου αποτυπώνεται στο ποσοστό των εσόδων που καταλήγει στην κατηγορία uncategorised, το οποίο αναφέρεται ρητά αντί να αποκρύπτεται.

8.3.3 Γεωγραφική ανάλυση σε επίπεδο χώρας

Η συσταδοποίηση πρώτου επιπέδου λειτουργεί σε όση γεωγραφική ανάλυση παρέχει η πηγή. Για το συγκεκριμένο σύνολο δεδομένων αυτή είναι η χώρα, ανάλυση χονδροειδής για επιχείρηση που δραστηριοποιείται κυρίως σε μία αγορά.

8.3.4 Ανώνυμες πωλήσεις

Σημαντικό ποσοστό των συναλλαγών δεν φέρει αναγνωριστικό πελάτη. Οι πωλήσεις αυτές διατηρούνται στις αναλύσεις προϊόντος, περιοχής και χρόνου, εξαιρούνται όμως αναγκαστικά από κάθε ανάλυση σε επίπεδο πελάτη, γεγονός που περιορίζει την πληρότητα των τελευταίων.

8.3.5 Ένα σύνολο δεδομένων

Η αξιολόγηση στηρίχθηκε σε ένα σύνολο δεδομένων, από μία επιχείρηση, μίας κατηγορίας. Η διαδρομή εισαγωγής έχει μεν ασκηθεί σε δεύτερη, δομικά άσχετη πηγή, όπως περιγράφεται στην ενότητα 3.4.1, τα ίδια όμως τα *ευρήματα* προέρχονται από ένα και μόνο κατάστημα. Το ποιες από τις παρατηρήσεις των κεφαλαίων αποτελεσμάτων γενικεύονται και ποιες αποτελούν ιδιαιτερότητες μιας χονδρικής επιχείρησης δώρων παραμένει ανοιχτό.

8.4 Μελλοντικές επεκτάσεις

- **Δεύτερο πραγματικό κατάστημα.** Οι τρεις οδοί παράδοσης δεδομένων καθιστούν την προσάρτηση ζήτημα παραμετροποίησης και όχι κώδικα. Αυτό που εκκρεμεί δεν είναι πλέον ο μηχανισμός αλλά η *σύγκριση των ευρημάτων* μεταξύ δύο πραγματικών καταστημάτων.

- **Προβλεπτική αξία διάρκειας ζωής.** Η παρούσα εργασία υπολογίζει παρατηρούμενη αξία. Η πρόβλεψή της με πιθανοτικά μοντέλα, όπως τα BG/NBD (Fader κ.ά., 2005a) και Gamma-Gamma, αποτελεί φυσική επέκταση. Τα μοντέλα αυτά συνδέονται άμεσα με την ανάλυση RFM του κεφαλαίου 7, καθώς προκύπτουν από τα ίδια τρία μεγέθη (Fader κ.ά., 2005b), και θα μετέτρεπαν την παρατηρούμενη αξία σε πρόβλεψη χωρίς πρόσθετες παραδοχές κόστους.

- **Γεωγραφική ιεραρχία.** Η προσθήκη επιπέδων κάτω από τη χώρα θα εμπλούτιζε τη συσταδοποίηση πρώτου επιπέδου χωρίς αλλαγή στον αναλυτικό κώδικα.

- **Χρονική εξέλιξη των κανόνων συσχέτισης.** Η σύγκριση διαδοχικών εκτελέσεων εξόρυξης θα ανεδείκνυε συσχετίσεις που εμφανίζονται ή εξασθενούν, πληροφορία που μια μεμονωμένη εκτέλεση δεν παρέχει.

- **Ενσωμάτωση στοιχείων κόστους.** Εφόσον μια επιχείρηση διαθέτει κόστος πωληθέντων και δαπάνες marketing, τα σενάρια του κεφαλαίου 7 μετατρέπονται σε μετρήσεις. Η αρχιτεκτονική το επιτρέπει χωρίς αλλαγή δομής.

8.5 Επίλογος

Η εργασία επιδίωξε δύο πράγματα ταυτόχρονα: να απαντήσει στα ερωτήματα που έθεσε η επιχείρηση, και να μην απαντήσει σε όσα τα δεδομένα δεν επιτρέπουν.

Το δεύτερο βγήκε εξίσου δύσκολο με το πρώτο. Το πόσο εύκολα μπορεί ένα σύστημα ανάλυσης να παρουσιάσει μια εύλογη εικασία σαν εύρημα είναι πραγματικός κίνδυνος,

και για να αντιμετωπιστεί χρειάστηκαν συγκεκριμένες σχεδιαστικές επιλογές: να χωρίζονται τα μετρούμενα από τα υποτιθέμενα μεγέθη, να ταξιδεύουν οι παραδοχές μαζί με κάθε αποτέλεσμα, και να δηλώνεται ρητά το μη ορισμένο εκεί όπου ένα μέγεθος δεν ορίζεται.

Α. Πηγαίος κώδικας

Παρατίθενται τα δύο αποσπάσματα στα οποία συμπυκνώνονται οι μεθοδολογικές επιλογές των κεφαλαίων 6 και 7. Ο πλήρης κώδικας είναι διαθέσιμος στο αποθετήριο της εργασίας. Η συσταδοποίηση υλοποιείται μέσω της βιβλιοθήκης scikit-learn (Pedregosa κ.ά., 2011) και η πρόβλεψη χρονοσειρών μέσω της βιβλιοθήκης statsmodels (Seabold & Perktold, 2010).

Α.1 Εμφωλευμένη συσταδοποίηση

Το πρώτο απόσπασμα υλοποιεί τη δομή δένδρου: μια κατάτμηση ως προς την περιοχή και τον χρόνο και, εντός κάθε συστάδας, δεύτερη κατάτμηση ως προς τα χαρακτηριστικά RFM. Οι εγγραφές δεύτερου επιπέδου συγκεντρώνονται για ολόκληρη τη συστάδα πριν την επανάληψη, ώστε το δεύτερο επίπεδο να περιγράφει την αγορά ως ενιαία οντότητα και όχι κάθε περιοχή χωριστά.

```
result = partition(
    rows,
    first_level_features,
    k_range=k_range,
    level=1,
    random_state=random_state,
)

for cluster in result.clusters:
    # Pool every second-level row belonging to any member of this
       cluster,
    # so the sub-clustering sees the group as a whole rather than
       one
    # member at a time.
    pooled: list[dict[str, Any]] = []
    for member in cluster.members:
        pooled.extend(second_level_rows.get(member, []))

    if not pooled:
        continue

    child = partition(
        pooled,
        second_level_features,
        k_range=k_range,
        label_prefix=f"{cluster.label}.",
```

```
        level=cluster.level + 1,
        random_state=random_state,
    )
    cluster.children = child.clusters
```

Listing A.1: Συσταδοποίηση δύο επιπέδων

Η επιλογή του πλήθους συστάδων γίνεται από τα δεδομένα. Για κάθε υποψήφια τιμή υπολογίζεται ο δείκτης περιγράμματος και κρατείται η καλύτερη, ενώ μια κατάτμηση που κατέρρευσε σε λιγότερες από δύο ομάδες δεν βαθμολογείται καθόλου.

```
scaled = StandardScaler().fit_transform(matrix)

for k in candidates:
    model = KMeans(n_clusters=k, random_state=random_state, n_init
       =10)
    labels = model.fit_predict(scaled)
    # An assignment that collapsed to fewer than k groups cannot be
       scored.
    if len(set(labels)) < 2:
        continue
    score = float(silhouette_score(scaled, labels))
    result.scores[k] = score
    if best_score is None or score > best_score:
        best_k, best_score, best_labels = k, score, labels
```

Listing A.2: Επιλογή του k με δείκτη περιγράμματος

A.2 Αποσύνθεση των εσόδων σε ροές

Το δεύτερο απόσπασμα κατατάσσει τα έσοδα κάθε πελάτη σε μία ακριβώς από τις έξι ροές της ενότητας 7.4. Η αποκλειστικότητα αυτή είναι που καθιστά τις λογιστικές ταυτότητες ελέγξιμες.

```
for customer, revenue in current.items():
    before = previous.get(customer, 0.0)
    if before > 0:
        # Active in both periods: the overlap is retained, and the
        # difference is expansion or contraction.
        result.retained += min(before, revenue)
        if revenue > before:
            result.expansion += revenue - before
        else:
            result.contraction += before - revenue
    elif customer in seen_before:
        result.resurrected += revenue
```

```
    else:
        result.new += revenue

for customer, before in previous.items():
    if current.get(customer, 0.0) == 0 and before > 0:
        result.churned += before
```

Listing A.3: Κατάταξη των εσόδων σε έξι ροές

Β. Αναλυτικά αποτελέσματα

Β.1 Πλήρες πλέγμα ευαισθησίας των μοναδιαίων οικονομικών

Ο πίνακας 7.3 του κεφαλαίου 7 παραθέτει επιλεγμένα κελιά. Εδώ παρατίθεται το πλέγμα στο σύνολό του, ώστε η κατανομή των θετικών και αρνητικών αποτελεσμάτων να είναι ελέγξιμη και όχι επιλεγμένη.

Η μέση παρατηρούμενη αξία ανά πελάτη είναι 2.895. Η αξία διάρκειας ζωής υπολογίζεται επί του μεικτού κέρδους, δηλαδή ως γινόμενο της αξίας αυτής με το υποτιθέμενο περιθώριο.

Περιθώριο	CAC	LTV	LTV:CAC	Πληροί 3:1
0,15	100	434	4,34	ναι
0,15	250	434	1,74	όχι
0,15	500	434	0,87	όχι
0,15	900	434	0,48	όχι
0,30	100	868	8,68	ναι
0,30	250	868	3,47	ναι
0,30	500	868	1,74	όχι
0,30	900	868	0,96	όχι
0,45	100	1.303	13,03	ναι
0,45	250	1.303	5,21	ναι
0,45	500	1.303	2,61	όχι
0,45	900	1.303	1,45	όχι
0,60	100	1.737	17,37	ναι
0,60	250	1.737	6,95	ναι
0,60	500	1.737	3,47	ναι
0,60	900	1.737	1,93	όχι

Πίνακας Β.1: Πλήρες πλέγμα ευαισθησίας, 16 κελιά

Οκτώ κελιά πληρούν το σημείο αναφοράς 3:1 και οκτώ όχι. Το κρίσιμο σημείο δεν είναι η αναλογία αυτή, η οποία εξαρτάται από το επιλεγμένο εύρος, αλλά το ότι το συμπέρασμα αντιστρέφεται εντός εύρους παραδοχών που όλες θα μπορούσαν να χαρακτηριστούν εύλογες.

Β.2 Δείκτες περιγράμματος ανά υποψήφιο πλήθος συστάδων

Οι βαθμολογίες του πρώτου επιπέδου παρατίθενται στον πίνακα 6.1. Η τιμή $k = 2$ υπερέχει σαφώς, και η πτώση από 0,8793 σε 0,7206 με μία μόνο επιπλέον συστάδα δείχνει ότι η δομή των δεδομένων είναι δυαδική και όχι βαθμιαία: η εγχώρια αγορά έναντι των εξαγωγικών.

ΒΙΒΛΙΟΓΡΑΦΙΑ

Agrawal, R., & Srikant, R. (1994). Fast Algorithms for Mining Association Rules in Large Databases. *Proceedings of the 20th International Conference on Very Large Data Bases (VLDB '94)*, 487–499.

Chen, D., Sain, S. L., & Guo, K. (2012). Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining. *Journal of Database Marketing & Customer Strategy Management*, *19*(3), 197–208. https://doi.org/10.1057/dbm.2012.17

Croll, A., & Yoskovitz, B. (2013). *Lean Analytics: Use Data to Build a Better Startup Faster*. O'Reilly Media.

Fader, P. S., Hardie, B. G. S., & Lee, K. L. (2005a). "Counting Your Customers" the Easy Way: An Alternative to the Pareto/NBD Model. *Marketing Science*, *24*(2), 275–284. https://doi.org/10.1287/mksc.1040.0098

Fader, P. S., Hardie, B. G. S., & Lee, K. L. (2005b). RFM and CLV: Using Iso-Value Curves for Customer Base Analysis. *Journal of Marketing Research*, *42*(4), 415–430. https://doi.org/10.1509/jmkr.2005.42.4.415

Gini, C. (1912). *Variabilità e Mutabilità: Contributo allo Studio delle Distribuzioni e delle Relazioni Statistiche*. Cuppini.

Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques* (3η έκδοση). Morgan Kaufmann.

Han, J., Pei, J., & Yin, Y. (2000). Mining Frequent Patterns without Candidate Generation. *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 1–12. https://doi.org/10.1145/342009.335372

Holt, C. C. (1957). Forecasting Seasonals and Trends by Exponentially Weighted Moving Averages [Reprinted in International Journal of Forecasting 20(1), 2004, 5–10, doi:10.1016/j.ijforecas *O.N.R. Memorandum*, *52*.

MacQueen, J. (1967). Some Methods for Classification and Analysis of Multivariate Observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, Volume 1: Statistics*, 281–297.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, *38*(4), 1346–1364. https://doi.org/10.1016/j.ijforecast.2021.11.013

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830.

Raschka, S. (2018). MLxtend: Providing Machine Learning and Data Science Utilities and Extensions to Python's Scientific Computing Stack. *Journal of Open Source Software*, *3*(24), 638. https://doi.org/10.21105/joss.00638

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, *20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and Statistical Modeling with Python. *Proceedings of the 9th Python in Science Conference*, 92–96. https://doi.org/10.25080/Majora-92bf1922-011

Winters, P. R. (1960). Forecasting Sales by Exponentially Weighted Moving Averages. *Management Science*, *6*(3), 324–342. https://doi.org/10.1287/mnsc.6.3.324